Clasificación del riesgo de caída en adultos mayores mediante análisis de marcha y aprendizaje automático: marco teórico y estado del arte

Versión 2 (3 de noviembre de 2026). Incorpora las observaciones de la revisión del profesor guía del 1 de noviembre: método de búsqueda, cinco estudios experimentales más, una tabla con datos, validación y métricas de cada estudio, el contexto nacional y varias correcciones.

***Resumen*: Las caídas son una de las principales causas de lesión y muerte en adultos mayores, y su prevención depende de detectar a tiempo a las personas en riesgo. Este documento presenta el marco teórico y el estado del arte sobre la clasificación del riesgo de caída a partir del análisis de la marcha con aprendizaje automático. Se describen los parámetros de marcha, los sensores inerciales y de video, los modelos Random Forest, XGBoost y LSTM, y las métricas de evaluación. Luego se revisan 26 fuentes, de las cuales 16 son trabajos científicos publicados entre 2020 y 2026. La literatura reporta un AUC combinado de 0,85 con sensores vestibles, pero con sensibilidad moderada, etiquetas en su mayoría retrospectivas y validaciones que no siempre separan por sujeto. A partir de estas brechas se justifican las decisiones metodológicas del proyecto.**

***Palabras clave*: análisis de marcha, riesgo de caída, adultos mayores, aprendizaje automático, sensores inerciales, estimación de pose.**

I. Introducción

Las caídas son la segunda causa mundial de muerte por traumatismos involuntarios, y las personas mayores de 60 años son el grupo que sufre más caídas mortales [1]. La Organización Mundial de la Salud estima que cada año mueren unas 684 000 personas por esta causa y que ocurren 37,3 millones de caídas que requieren atención médica [1]. Además del daño físico, una caída suele traer pérdida de independencia y miedo a volver a caer. En Chile, la encuesta SABE registró que el 34,0 % de las personas mayores de Santiago que viven en la comunidad se había caído en el último año, la cifra más alta entre las siete ciudades de América Latina y el Caribe estudiadas [27].

Las guías mundiales de prevención de caídas recomiendan buscar de forma activa a los adultos mayores en riesgo, porque muchos no consultan después de caerse [2]. En la práctica, esa evaluación se hace con pruebas clínicas que necesitan un profesional capacitado, tiempo y espacio físico. Esto limita la cantidad de personas que se pueden evaluar, sobre todo en la atención primaria.

La forma de caminar entrega información útil sobre el riesgo de caída. En los últimos años se han desarrollado sistemas que miden la marcha con sensores de bajo costo y la analizan con modelos de aprendizaje automático, con el fin de obtener una evaluación objetiva y automática. Este documento revisa esos trabajos como primera etapa de un proyecto que busca clasificar el riesgo de caída en adultos mayores a partir de datos abiertos de marcha.

El documento se organiza así. La Sección II presenta los conceptos necesarios para entender los estudios. La Sección III revisa el estado del arte a nivel mundial. La Sección IV compara los estudios en una tabla y la Sección V resume las brechas encontradas y cómo se relacionan con el proyecto.

II. Marco teórico

Para clasificar el riesgo de caída a partir de la marcha se necesitan cuatro elementos: variables que describan la marcha, un sensor que las mida, un modelo que aprenda a clasificar y una forma de evaluar ese modelo. Esta sección explica cada uno.

A. La marcha humana y sus parámetros

La marcha es un movimiento cíclico. Un ciclo, llamado zancada, va desde que un talón toca el suelo hasta que el mismo talón lo vuelve a tocar. Cada ciclo tiene una fase de apoyo, cuando el pie está en el suelo (cerca del 60 % del ciclo), y una fase de balanceo, cuando el pie va en el aire.

A partir del ciclo se calculan los parámetros espaciotemporales, que son las variables más usadas en los estudios revisados:

Parámetro	Unidad	Descripción
Velocidad de marcha	m/s	Distancia recorrida por unidad de tiempo
Largo de zancada	m	Distancia entre dos apoyos seguidos del mismo pie
Cadencia	pasos/min	Número de pasos por minuto
Tiempo de zancada	s	Duración de un ciclo completo
Fase de apoyo	%	Parte del ciclo en que el pie está en el suelo
Variabilidad	%	Cambio de un parámetro entre una zancada y otra
Asimetría	%	Diferencia entre la pierna izquierda y la derecha

La variabilidad se expresa normalmente como coeficiente de variación, donde σ es la desviación estándar y μ el promedio del parámetro sobre todas las zancadas:

La variabilidad es importante porque una persona con buen control del equilibrio repite casi el mismo paso cada vez. Un estudio prospectivo clásico encontró que la variabilidad del tiempo de zancada se asocia con el riesgo de caer durante el año siguiente [3].

B. Sensores para medir la marcha

Los estudios revisados usan dos tipos de sensores.

Sensores inerciales. Una unidad de medición inercial (IMU) combina un acelerómetro, que mide aceleración lineal en tres ejes, y un giroscopio, que mide velocidad angular en tres ejes. Se fija al cuerpo, por ejemplo en la zona lumbar, el pie o la muñeca, y entrega una señal muestreada en el tiempo. De esa señal se detectan los apoyos del pie y se calculan los parámetros de la Tabla anterior.

Cámaras y estimación de pose. Un modelo de visión por computador recibe un video y entrega la posición de las articulaciones en cada cuadro, sin marcadores ni sensores sobre la persona. Un ejemplo es BlazePose, la red que usa MediaPipe Pose, diseñada para funcionar en tiempo real en dispositivos de bajo consumo [4]. Con las trayectorias de las articulaciones se pueden calcular parámetros de marcha parecidos a los que entrega una IMU.

C. Modelos de aprendizaje automático

Todos los modelos considerados son de aprendizaje supervisado: se entrenan con ejemplos que ya tienen una etiqueta conocida (riesgo alto o riesgo bajo) y después se usan para clasificar casos nuevos. En este proyecto se comparan tres.

Random Forest. Entrena muchos árboles de decisión, cada uno con una muestra aleatoria de los datos y de las variables, y clasifica por votación de todos los árboles [5]. Es robusto y tiene pocos parámetros que ajustar.

XGBoost. También usa árboles de decisión, pero los construye en serie: cada árbol nuevo se entrena para corregir los errores de los anteriores, y la predicción final es la suma de todos [6]. Suele dar muy buenos resultados con datos en forma de tabla.

LSTM. Es una red neuronal recurrente que procesa una secuencia paso a paso y mantiene una memoria interna, controlada por compuertas que deciden qué información guardar y cuál olvidar [7]. Puede recibir directamente la señal del sensor, sin calcular antes los parámetros de marcha, pero necesita más datos para entrenarse.

La diferencia principal es la entrada. Random Forest y XGBoost reciben una tabla de parámetros ya calculados. Una LSTM puede recibir la señal cruda y aprender por sí misma qué patrones son relevantes.

D. Métricas y validación

Un clasificador se evalúa comparando sus predicciones con las etiquetas reales. Si VP, VN, FP y FN son los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, las métricas más usadas son:

La exactitud (*accuracy*) puede engañar cuando hay menos casos de riesgo alto que de riesgo bajo. Por eso se reportan también la sensibilidad, el F1-score, que combina precisión y sensibilidad, y el área bajo la curva ROC (AUC), que vale 0,5 para un modelo al azar y 1,0 para uno perfecto.

Para estimar cómo funcionará el modelo con personas nuevas se usa validación cruzada: los datos se dividen en k partes, se entrena con k−1 y se prueba con la restante, rotando hasta usar todas. Cuando hay varios registros por persona, la división debe hacerse por sujeto. Si registros de una misma persona quedan en entrenamiento y en prueba, el modelo puede aprender a reconocer a la persona y el resultado sale más alto de lo real [8].

III. Estado del arte

La investigación mundial ha pasado de las pruebas clínicas con cronómetro a sistemas que miden la marcha con sensores y la clasifican con aprendizaje automático. Esta sección revisa esa evolución en cinco partes.

Método de búsqueda. Los trabajos se buscaron en [completar: IEEE Xplore, Google Scholar, PubMed u otras], con las palabras clave [completar: por ejemplo, «fall risk» AND «gait» AND («machine learning» OR «deep learning»), en inglés y español]. La búsqueda se hizo entre [completar: fechas]. Se incluyeron artículos publicados entre 2020 y 2026, en inglés o español, que clasificaran el riesgo de caída o el historial de caídas de personas adultas a partir de la marcha o de pruebas que la incluyen, medida con sensores o con video, usando aprendizaje automático. Se excluyeron los trabajos sobre detección de caídas en el momento en que ocurren, los que no informaban métricas de clasificación y los resúmenes de congresos sin texto completo. Además de esos estudios experimentales, se incluyeron revisiones sistemáticas, guías clínicas, los trabajos que definen los modelos y las bases de datos, y algunos estudios clásicos anteriores a 2020 que son necesarios para el marco teórico.

En total, el documento reúne 34 fuentes. De las publicadas entre 2020 y 2026, 14 son estudios experimentales de clasificación del riesgo de caída (Tablas I y II); las demás son revisiones, guías o trabajos de apoyo, como el modelo de pose BlazePose [4] o la validación de la marcha medida con video [21]. La primera versión de este documento contaba como parte de los 15 trabajos pedidos varias fuentes que no son estudios experimentales, por lo que en esta versión se agregaron cinco estudios experimentales [28]–[32].

A. Evaluación clínica tradicional

La prueba más conocida es el Timed Up and Go (TUG), en la que se mide el tiempo que tarda la persona en levantarse de una silla, caminar tres metros, volver y sentarse [9]. Es simple y no requiere equipos, pero entrega un solo número y depende de quien la aplica. Una revisión sistemática con metaanálisis concluyó que el TUG tiene una capacidad limitada para predecir caídas en adultos mayores que viven en la comunidad y que no debería usarse como única herramienta [10]. Esta limitación es una de las razones que impulsan el uso de sensores.

B. Sensores vestibles y aprendizaje automático

Los primeros trabajos con sensores usaron estadística para comparar grupos. Weiss et al. registraron durante tres días a 71 adultos mayores con un acelerómetro en la zona lumbar y encontraron que quienes tenían historial de caídas no caminaban menos, sino con menor regularidad [11]. Además, siguieron a los participantes durante seis meses, y las medidas de los tres días mejoraron la identificación de caídas pasadas y futuras respecto de las pruebas clínicas. Este estudio dio origen a una de las bases de datos abiertas más usadas en el tema.

Los trabajos posteriores incorporaron modelos de clasificación. Noh et al. midieron a 746 adultos mayores en Corea del Sur con sensores inerciales en los zapatos y entrenaron un modelo XGBoost, con una exactitud de 67 a 70 % y una sensibilidad de 43 a 53 % [12]. Las variables más importantes fueron el largo de zancada, la velocidad y la fase de apoyo. Lockhart et al., en Estados Unidos, usaron un solo sensor en el esternón, una caminata de 10 metros y un modelo Random Forest; al probarlo con personas seguidas durante seis meses obtuvieron 81,6 % de exactitud [13]. En España, García-de-Villa et

al. clasificaron a 157 personas mayores de 70 años con una máquina de vectores de soporte y un sensor en el pie, con 79,6 % de exactitud, levemente sobre el método basado solo en velocidad de marcha [14].

Las revisiones sistemáticas confirman estos resultados y muestran sus límites. Chen et al. analizaron 25 estudios y concluyeron que no existe consenso sobre la ubicación del sensor, la frecuencia de muestreo ni el modelo a usar [15]. Bezold et al. revisaron 28 estudios e incluyeron a personas con deterioro cognitivo, en quienes los modelos rindieron algo peor [16]. El metaanálisis más reciente, de Mou et al., combinó 20 estudios y obtuvo un AUC de 0,85, con especificidad alta (0,89) y sensibilidad moderada (0,55) [17]. El mismo trabajo encontró que los estudios con aprendizaje automático rinden mejor que los que no lo usan (AUC de 0,90 frente a 0,79), y que los estudios con menos de 100 participantes reportan resultados más altos, lo que sugiere riesgo de sobreajuste.

Otros estudios recientes muestran la variedad de diseños. Buisseret et al. midieron a 73 residentes de hogares de ancianos con un sensor inercial durante el TUG y una caminata de seis minutos, y registraron las caídas de los seis meses siguientes; un algoritmo de inteligencia artificial entrenado con la señal alcanzó 75 % de exactitud en las 16 personas de prueba [28]. Wang et al. usaron variables de un ciclo de marcha de 298 adultos mayores sanos para predecir si caerían ante un tropiezo provocado en el laboratorio, con un AUC de 0,96 [29]. En Chile, Robles Cruz et al., en un trabajo registrado en el repositorio institucional de la UNAB, clasificaron a 181 personas mayores según su historial de caídas con los sensores de un teléfono durante el Mini-BESTest y una red LSTM, con 88,6 % de exactitud y un F1-score de 89,0 % [30]. Neira Álvarez et al. usaron el sensor de pie G-STRIDE en 163 personas mayores de 70 años para estratificarlas según fragilidad y caídas con Random Forest [31].

C. Aprendizaje profundo

En los últimos años se han probado redes neuronales que reciben la señal del sensor directamente. Kiprijanovska et al. combinaron capas convolucionales con una LSTM bidireccional sobre datos de relojes inteligentes y lograron 88,9 % de exactitud, aunque con 18 voluntarios que simulaban una marcha alterada y no con adultos mayores reales [18]. Altunkaya aplicó una red neuronal multicapa, con selección de características, a las caminatas de laboratorio de la base LTMM (73 registros: 38 personas que no caen y 35 que caen) y obtuvo 82,2 % de exactitud, la mejor de varias configuraciones probadas [19].

El trabajo más reciente es el de Alqurashi et al., que comparó modelos tradicionales con redes CNN y LSTM en 163 personas de 70 a 98 años [20]. Las redes alcanzaron 95 a 96 % de exactitud cuando los datos se dividieron al azar, pero bajaron a 87 a 92 % cuando la división se hizo por sujeto. Este resultado muestra que la forma de validar influye tanto como el modelo elegido, y coincide con la advertencia de [8].

Con las mismas caminatas y registros de LTMM, Askhatova et al. combinaron una red convolucional temporal (TCN) que lee la señal con variables calculadas de laboratorio y de vida diaria, en 63 personas, y obtuvieron un AUC medio de 0,75 con validación cruzada de cinco partes separando por sujeto, con valores entre 0,53 y 0,93 según la partición [32]. Es el trabajo más cercano a este proyecto.

D. Visión por computador y estimación de pose

Una línea más nueva reemplaza el sensor por una cámara común. Stenum et al. compararon los parámetros de marcha obtenidos con estimación de pose desde video contra un sistema de captura de

movimiento tridimensional, y la diferencia en velocidad de marcha fue menor que 0,10 m/s [21]. Esto indica que una cámara puede medir la marcha con una precisión útil.

Sobre esa base, Ng et al. analizaron 1066 videos de 31 adultos mayores con demencia caminando en un pasillo y encontraron que las variables extraídas se asociaban con el número de caídas posteriores [22]. Lim et al. extrajeron tiempos de zancada, cadencia y tiempo de apoyo desde videos de la prueba TUG y los clasificaron con modelos simples de aprendizaje automático [23]. Otro estudio, con trabajadores de mediana edad, usó una cámara RGB y MediaPipe para analizar los tres primeros pasos, con un AUC de 0,909 en hombres y solo 0,670 en mujeres [24].

E. Bases de datos abiertas

PhysioNet es el principal repositorio abierto de señales fisiológicas [25]. Allí está disponible la base Long Term Movement Monitoring (LTMM), que contiene los registros del estudio de Weiss et al. [11], etiquetados según si tuvieron dos o más caídas en el último año. Tiene dos conjuntos que no coinciden del todo: 71 registros de tres días de vida diaria y 73 caminatas de laboratorio de un minuto (carpeta LabWalks: 38 personas que no caen y 35 que caen). Weiss et al. informan 71 participantes, que corresponden a los registros de tres días. PhysioNet también aloja la base Gait in Aging and Disease, pero solo tiene 15 personas y no incluye etiquetas de caída.

La base CASIA, de la Academia China de Ciencias, contiene videos y siluetas de personas caminando desde varios ángulos [26]. Fue creada para identificar personas por su forma de caminar, por lo que no tiene etiquetas de riesgo de caída. Podría servir para probar algoritmos de estimación de pose, pero no para entrenar un clasificador de riesgo.

Como la muestra de LTMM es pequeña, se buscaron otras bases públicas con etiquetas de caída. La más cercana es G-STRIDE, de García-de-Villa et al., con métricas de marcha de un sensor en el pie, pruebas funcionales y fragilidad de personas mayores, que incluye la causa de las caídas [33]. Su sensor está en el pie y no en la zona lumbar, por lo que no sirve para entrenar con las mismas variables, pero podría usarse para una validación externa de un modelo basado en el ritmo de la marcha. Gait in Aging and Disease y CASIA no tienen etiquetas de caída.

IV. Comparación de los estudios

La Tabla I resume los estudios experimentales revisados y la Tabla II, los datos que usaron, cómo validaron y qué métricas informaron. Se observa que el resultado más alto, 96 % [23], proviene de una muestra pequeña, con etiquetas basadas en escalas clínicas y evaluada con una sola división de prueba; que solo cuatro estudios incluyen un seguimiento prospectivo; y que solo tres validaron separando por sujeto de forma explícita. También se ve que las métricas no son homogéneas: varios estudios informan solo la exactitud, lo que dificulta compararlos.

TABLA I. Estudios experimentales sobre clasificación del riesgo de caída a partir de la marcha

Ref.	Año	Participantes	Sensor	Modelo	Resultado principal	Tipo de etiqueta
[11]	2013	71 adultos mayores	Acelerómetro lumbar, 3 días	Comparación estadística	Menor regularidad de la marcha en quienes caen	Retrospectiva, con seguimiento de 6 meses
[18]	2020	18 voluntarios	Relojes inteligentes en ambas muñecas	CNN con LSTM bidireccional	Exactitud 88,9 %	Marcha alterada simulada
[22]	2020	31 adultos mayores con demencia	Cámara y estimación de pose	Análisis de asociación	Variables de marcha asociadas a caídas futuras	Prospectiva
[12]	2021	746 adultos mayores	IMU en ambos zapatos	XGBoost	Exactitud 67-70 %, sensibilidad 43-53 %	Retrospectiva
[13]	2021	171 adultos mayores	IMU en el esternón	Random Forest	Exactitud 81,6 %, sensibilidad 86,7 %	Prospectiva, 6 meses
[19]	2024	71 adultos mayores (base LTMM)	Acelerómetro en la cintura, caminata de 1 min	Red neuronal multicapa	Exactitud 82,2 %, sensibilidad 82,9 %	Retrospectiva
[23]	2024	65 personas: adultos jóvenes sin caídas y adultos mayores que caen	Dos cámaras y estimación de pose	LightGBM y MLP, entre 12 clasificadores	Exactitud 96 % en una sola división de prueba	Escalas clínicas (JHFRAT y POMA)
[14]	2025	157 mayores de 70 años	IMU en el pie	Máquina de vectores de soporte	Exactitud 79,6 %	Retrospectiva
[24]	2025	190 trabajadores de mediana edad	Cámara RGB y MediaPipe	Aprendizaje automático	AUC 0,909 en hombres y 0,670 en mujeres	Retrospectiva

Ref.	Año	Participantes	Sensor	Modelo	Resultado principal	Tipo de etiqueta
[20]	2026	163 personas de 70 a 98 años	IMU	CNN y LSTM	Exactitud 87-92 % validando por sujeto	Retrospectiva
[28]	2020	73 residentes de hogares de ancianos	IMU durante el TUG y una caminata de 6 min	Algoritmo de IA sobre la señal	Exactitud 75 % en 16 personas de prueba	Prospectiva, 6 meses
[29]	2023	298 adultos mayores sanos	Variables de un ciclo de marcha	Ensamble de árboles (bagging)	AUC 0,96	Caída ante un tropiezo provocado
[30]	2024	181 personas mayores (Chile)	Sensores de un teléfono durante el Mini-BESTest	LSTM	Exactitud 88,6 %, F1 89,0 %	Retrospectiva
[31]	2024	163 mayores de 70 años	IMU en el pie (G-STRIDE)	Random Forest	Estratificación por fragilidad y caídas	Retrospectiva
[32]	2026	63 adultos mayores (base LTMM)	Acelerómetro y giroscopio lumbares, 1 min y 3 días	TCN con variables calculadas	AUC medio 0,75, validando por sujeto	Retrospectiva

TABLA II. Datos, validación y métricas de los estudios de la Tabla I

Ref.	Datos	Validación	AUC	Sensibilidad	F1
[11]	Propios; hoy públicos (LTMM)	Regresión logística evaluada con los mismos datos	NR	NR	NR
[18]	Propios (18 voluntarios)	Dejando un sujeto fuera (por sujeto)	NR	90,6 %	NR
[22]	Propios	Análisis de asociación, sin clasificador	NA	NA	NA
[12]	Propios (746 personas)	División 70/30 y validación cruzada de 10 partes al azar	0,71-0,72	43-53 %	NR

Ref.	Datos	Validación	AUC	Sensibilidad	F1
[13]	Propios (171 personas)	Estimación fuera de bolsa de Random Forest y prueba ciega	NR	86,7 %	NR
[19]	Públicos (LTMM)	Validación cruzada de 10 partes; mejor de varias configuraciones	0,863	82,9 %	NR
[23]	Propios	Una sola división 80/20, con datos sintéticos (SMOTE)	NR	NR	NR
[14]	157 mayores de 70 años	Validación cruzada de k partes al azar	NR	NR	NR
[24]	Propios (190 personas)	Validación cruzada estratificada de k partes	0,909 y 0,670	NR	NR
[20]	Propios (163 personas)	10 partes al azar y 10 partes por sujeto	NR	NR	NR
[28]	Propios (73 personas)	Una sola división: 57 para entrenar y 16 para probar	NR	NR	NR
[29]	Propios (298 personas)	Validación cruzada estratificada 5 × 10, una prueba por persona	0,96	Por clase	NR
[30]	Propios (181 personas)	No se describe en el resumen	NR	87,9 %	89,0 %
[31]	Propios (163 personas)	No se describe en el resumen	NR	NR	NR
[32]	Públicos (LTMM)	Validación cruzada de 5 partes por sujeto	0,749	NR	NR

NR: no reportado o no encontrado en el texto revisado. NA: no aplica, porque el estudio no entrenó un clasificador. Las cifras corresponden al mejor resultado que informa cada estudio.

V. Brechas identificadas y relación con el proyecto

La literatura muestra que es posible clasificar el riesgo de caída a partir de la marcha, pero deja cinco brechas que este proyecto debe tener en cuenta.

1. **Etiquetas retrospectivas.** La mayoría de los estudios clasifica a personas que ya se cayeron. Solo algunos siguen a los participantes para registrar caídas futuras [11], [13], [22], [28], y esos son los que realmente evalúan predicción [17].

2. **Validación poco rigurosa.** Dividir los datos al azar, sin separar por sujeto, entrega resultados más altos de lo real [8], [20]. Lo mismo ocurre cuando se evalúa con una sola división de prueba o se generan datos sintéticos antes de separar entrenamiento y prueba, como en [23]. Las muestras pequeñas agravan el problema [17].
3. **Sensibilidad baja.** Los modelos identifican bien a quienes no tienen riesgo, pero dejan pasar a una parte importante de quienes sí lo tienen [12], [17]. Para una herramienta de prevención, ese es el error más costoso.
4. **Falta de estandarización.** No hay acuerdo sobre dónde poner el sensor, qué prueba aplicar ni qué variables calcular [15], lo que dificulta comparar resultados entre estudios.
5. **Pocos estudios con cámara en adultos mayores.** Los trabajos con estimación de pose se han hecho en personas con demencia [22], en trabajadores de mediana edad [24] o en grupos que mezclan adultos jóvenes sin caídas con adultos mayores que caen [23]. La evidencia en adultos mayores de la comunidad con una cámara común todavía es limitada.

A partir de estas brechas se definen las decisiones de la primera etapa del proyecto. Cada una se apoya en los trabajos revisados en la Sección III:

- **Datos.** Se propone usar la base LTMM [11], [25], porque es abierta y tiene etiquetas de caída. Se reconoce que sus etiquetas son retrospectivas y que tiene pocas personas (73 caminatas de laboratorio y 71 registros de tres días), lo que según [17] aumenta el riesgo de sobreajuste.
- **Variables.** Se calcularán medidas de ritmo, variabilidad y regularidad, siguiendo el hallazgo de Weiss et al. [11]. Los parámetros más importantes en Noh et al. [12] (largo de zancada, velocidad y fase de apoyo) necesitan sensores en los pies; con el sensor lumbar de LTMM no se pueden calcular directamente. El largo de paso podría estimarse con un modelo de péndulo invertido [34], que requiere la altura del sensor. Esta corrección se hizo después de la sub-etapa 1.2, donde se confirmó la limitación. Lockhart et al. [13] respaldan que un solo sensor en el tronco, como el de LTMM, basta para clasificar.
- **Modelos.** Se compararán Random Forest [5], XGBoost [6] y LSTM [7]. Los dos primeros trabajarán sobre las variables calculadas, y el diseño de la LSTM tomará como referencia a [18] y [20].
- **Validación.** Se usará validación cruzada separando por sujeto, de acuerdo con [8] y [20].
- **Métricas.** Se reportarán exactitud, sensibilidad, F1-score y AUC, y no solo la exactitud.
- **Comparación.** Los resultados se compararán con los de Altunkaya [19], que usó las mismas caminatas de LTMM; con un método simple basado solo en la velocidad de marcha, como el que usaron García-de-Villa et al. [14] (como el sensor lumbar no mide la velocidad, en la sub-etapa 1.4 se usó la velocidad registrada en la planilla clínica de LTMM); y con el resultado del TUG que LTMM incluye para cada persona, considerando las limitaciones de esta prueba [9], [10]. El AUC de 0,85 del metaanálisis [17] servirá como referencia general.
- **Documentación.** Para responder a la falta de estandarización señalada en [15] y [16], se registrarán la ubicación del sensor, la frecuencia de muestreo y las variables usadas, de modo que los resultados se puedan comparar con otros estudios.

La segunda etapa, que busca llevar el modelo a una cámara común con MediaPipe [4], se apoya en los trabajos de visión revisados: [21] muestra que una cámara mide la marcha con una precisión útil, [22] y [23] extraen parámetros de marcha desde video para estimar el riesgo de caída, y [24] describe un protocolo de captura con MediaPipe. La base CASIA [26] no sirve para entrenar el clasificador, pero

podría usarse para probar la estimación de pose. Un punto pendiente es que LTMM contiene señales de acelerómetro y el prototipo usará video, por lo que habrá que trabajar con parámetros de marcha que ambos sensores puedan medir.

Referencias

[1] Organización Mundial de la Salud, "Caídas," nota descriptiva, 26 abr. 2021. [En línea]. Disponible: https://www.who.int/es/news-room/fact-sheets/detail/falls (accedido: 6 oct. 2026).

[2] M. Montero-Odasso *et al.*, "World guidelines for falls prevention and management for older adults: A global initiative," *Age Ageing*, vol. 51, no. 9, Art. no. afac205, Sep. 2022, doi: 10.1093/ageing/afac205.

[3] J. M. Hausdorff, D. A. Rios, and H. K. Edelberg, "Gait variability and fall risk in community-living older adults: A 1-year prospective study," *Arch. Phys. Med. Rehabil.*, vol. 82, no. 8, pp. 1050–1056, Aug. 2001, doi: 10.1053/apmr.2001.24893.

[4] V. Bazarevsky, I. Grishchenko, K. Raveendran, T. Zhu, F. Zhang, and M. Grundmann, "BlazePose: On-device real-time body pose tracking," 2020, *arXiv:2006.10204*.

[5] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[6] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[7] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[8] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," *GigaScience*, vol. 6, no. 5, Art. no. gix019, May 2017, doi: 10.1093/gigascience/gix019.

[9] D. Podsiadlo and S. Richardson, "The timed 'Up & Go': A test of basic functional mobility for frail elderly persons," *J. Amer. Geriatr. Soc.*, vol. 39, no. 2, pp. 142–148, Feb. 1991, doi: 10.1111/j.1532-5415.1991.tb01616.x.

[10] E. Barry, R. Galvin, C. Keogh, F. Horgan, and T. Fahey, "Is the Timed Up and Go test a useful predictor of risk of falls in community dwelling older adults: A systematic review and meta-analysis," BMC Geriatr., vol. 14, Art. no. 14, Feb. 2014, doi: 10.1186/1471-2318-14-14.

[11] A. Weiss *et al.*, "Does the evaluation of gait quality during daily life provide insight into fall risk? A novel approach using 3-day accelerometer recordings," *Neurorehabil. Neural Repair*, vol. 27, no. 8, pp. 742–752, Oct. 2013, doi: 10.1177/1545968313491004.

[12] B. Noh *et al.*, "XGBoost based machine learning approach to predict the risk of fall in older adults using gait outcomes," *Sci. Rep.*, vol. 11, Art. no. 12183, Jun. 2021, doi: 10.1038/s41598-021-91797-w.

[13] T. E. Lockhart *et al.*, "Prediction of fall risk among community-dwelling older adults using a wearable system," *Sci. Rep.*, vol. 11, Art. no. 20976, Oct. 2021, doi: 10.1038/s41598-021-00458-5.

[14] S. García-de-Villa *et al.*, "Validation of an IMU-based gait analysis method for assessment of fall risk against traditional methods," *IEEE J. Biomed. Health Inform.*, vol. 29, no. 1, pp. 107–117, Jan. 2025, doi: 10.1109/JBHI.2024.3434973.

[15] M. Chen *et al.*, "A systematic review of wearable sensor-based technologies for fall risk assessment in older adults," *Sensors*, vol. 22, no. 18, Art. no. 6752, Sep. 2022, doi: 10.3390/s22186752.

[16] J. Bezold, J. Krell-Roesch, T. Eckert, D. Jekauc, and A. Woll, "Sensor-based fall risk assessment in older adults with or without cognitive impairment: A systematic review," *Eur. Rev. Aging Phys. Act.*, vol. 18, Art. no. 15, 2021, doi: 10.1186/s11556-021-00266-w.

[17] C. Mou, X. Yan, X. Miao, and L. Zhu, "Accuracy of wearable devices in predicting falls in older adults: A systematic review and meta-analysis," *Front. Public Health*, vol. 14, Art. no. 1778750, Mar. 2026, doi: 10.3389/fpubh.2026.1778750.

[18] I. Kiprijanovska, H. Gjoreski, and M. Gams, "Detection of gait abnormalities for fall risk assessment using wrist-worn inertial sensors and deep learning," *Sensors*, vol. 20, no. 18, Art. no. 5373, Sep. 2020, doi: 10.3390/s20185373.

[19] S. Altunkaya, "Leveraging feature selection for enhanced fall risk prediction in elderly using gait analysis," *Med. Biol. Eng. Comput.*, vol. 62, pp. 3887–3897, 2024, doi: 10.1007/s11517-024-03180-2.

[20] A. Alqurashi, A. Alharthi, M. M. Alammar, N. Aldosari, and A. Al Ayidh, "Classification of fallers and non-fallers in older adults using electrical IMU signal for gait analysis and explainable deep learning," *Sci. Rep.*, vol. 16, no. 1, Art. no. 14353, Mar. 2026, doi: 10.1038/s41598-026-44368-w.

[21] J. Stenum, C. Rossi, and R. T. Roemmich, "Two-dimensional video-based analysis of human gait using pose estimation," *PLoS Comput. Biol.*, vol. 17, no. 4, Art. no. e1008935, Apr. 2021, doi: 10.1371/journal.pcbi.1008935.

[22] K.-D. Ng *et al.*, "Measuring gait variables using computer vision to assess mobility and fall risk in older adults with dementia," *IEEE J. Transl. Eng. Health Med.*, vol. 8, pp. 1–9, 2020, doi: 10.1109/JTEHM.2020.2998326.

[23] Z. K. Lim, T. Connie, M. K. O. Goh, and N. I. B. Saedon, "Fall risk prediction using temporal gait features and machine learning approaches," *Front. Artif. Intell.*, vol. 7, Art. no. 1425713, Aug. 2024, doi: 10.3389/frai.2024.1425713.

[24] N. Sakane et al., "Application of machine learning for detecting high fall risk in middle-aged workers using video-based analysis of the first 3 steps," *J. Occup. Health*, vol. 67, no. 1, Art. no. uiae075, Jan. 2025, doi: 10.1093/joccuh/uiae075.

[25] A. L. Goldberger *et al.*, "PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals," *Circulation*, vol. 101, no. 23, pp. e215–e220, Jun. 2000, doi: 10.1161/01.CIR.101.23.e215.

[26] S. Yu, D. Tan, and T. Tan, "A framework for evaluating the effect of view angle, clothing and carrying condition on gait recognition," in *Proc. 18th Int. Conf. Pattern Recognit. (ICPR)*, Hong Kong, China, 2006, vol. 4, pp. 441–444, doi: 10.1109/ICPR.2006.67.

[27] C. A. Reyes-Ortiz, S. Al Snih, and K. S. Markides, "Falls among elderly persons in Latin America and the Caribbean and among elderly Mexican-Americans," Rev. Panam. Salud Publica, vol. 17, no. 5/6, pp. 362–369, 2005.

[28] F. Buisseret et al., "Timed Up and Go and Six-Minute Walking Tests with wearable inertial sensor: One step further for the prediction of the risk of fall in elderly nursing home people," Sensors, vol. 20, no. 11, Art. no. 3207, Jun. 2020, doi: 10.3390/s20113207.

[29] S. Wang, T. K. Nguyen, and T. Bhatt, "Trip-related fall risk prediction based on gait pattern in healthy older adults: A machine-learning approach," Sensors, vol. 23, no. 12, Art. no. 5536, Jun. 2023, doi: 10.3390/s23125536.

[30] D. Robles Cruz et al., "Fall risk classification using trunk movement patterns from inertial measurement units and Mini-BESTest in community-dwelling older adults: A deep learning approach," Appl. Sci., vol. 14, no. 20, Art. no. 9170, Oct. 2024, doi: 10.3390/app14209170.

[31] M. Neira Álvarez et al., "Stratification of older adults according to frailty status and falls using gait parameters explored using an inertial system," Appl. Sci., vol. 14, no. 15, Art. no. 6704, Aug. 2024, doi: 10.3390/app14156704.

[32] A. Askhatova et al., "A temporal convolutional network approach for gait-based fall risk prediction to support safe sport participation in older adults," MethodsX, vol. 16, Art. no. 103845, 2026, doi: 10.1016/j.mex.2026.103845.

[33] S. García-de-Villa et al., "A database with frailty, functional and inertial gait metrics for the research of fall causes in older adults," Sci. Data, vol. 10, 2023.

[34] W. Zijlstra and A. L. Hof, "Assessment of spatio-temporal gait parameters from trunk accelerations during human walking," Gait Posture, vol. 18, no. 2, pp. 1–10, Oct. 2003, doi: 10.1016/S0966-6362(02)00190-X.