Clasificación del riesgo de caída en adultos mayores mediante análisis de marcha y aprendizaje automático: avance de la sub-etapa 1.2, obtención y preparación de datos

***Resumen*: Este documento presenta el avance de la sub-etapa 1.2 del proyecto, correspondiente a las semanas 4 y 5. Se obtuvieron y prepararon dos fuentes de datos abiertas: las 73 caminatas de laboratorio de la base Long Term Movement Monitoring (LTMM) de PhysioNet, registradas con un sensor inercial en la zona lumbar, y las siluetas de las bases A, B y C de CASIA Gait Database. Las señales de LTMM se revisaron y se limpiaron; un registro se excluyó porque su detección de pasos no era confiable, y las 72 personas restantes se resumieron en 17 variables de marcha, de las que 14 se conservaron para los modelos tras eliminar las redundantes. El resultado es un dataset limpio y documentado. El análisis exploratorio mostró que las personas que caen caminan con una frecuencia dominante menor que las que no caen (1,78 Hz frente a 1,93 Hz; p corregido = 0,007), y con tendencia a una menor cadencia y a tiempos de paso más largos. Las bases de CASIA están prácticamente completas, y la cadencia estimada desde las siluetas cambia según la velocidad de marcha. Con esto, los datos quedan listos para entrenar los modelos de la sub-etapa 1.3.**

***Palabras clave*: análisis de marcha, riesgo de caída, preparación de datos, análisis exploratorio, PhysioNet, CASIA.**

I. Introducción

El proyecto busca clasificar el riesgo de caída en adultos mayores a partir de su forma de caminar, usando aprendizaje automático. En la Etapa 1 se trabaja solo con datos abiertos, y en la Etapa 2 el modelo se llevará a un prototipo con una cámara común y MediaPipe. La sub-etapa 1.2, desarrollada en las semanas 4 y 5, tiene como objetivo obtener y preparar los datos que se usarán en el resto del proyecto.

Las actividades planificadas fueron descargar y explorar las bases de PhysioNet y CASIA, limpiar las variables de marcha y realizar un análisis exploratorio de datos (EDA). El producto comprometido es un dataset limpio y documentado, junto con los notebooks del análisis.

El documento se organiza así. La Sección II describe las bases de datos usadas. La Sección III explica el procesamiento y el análisis. La Sección IV presenta los resultados y la Sección V los discute. La Sección VI resume las decisiones tomadas y la Sección VII, los productos entregados y los próximos pasos.

II. Datos utilizados

A. Base LTMM (PhysioNet)

La base Long Term Movement Monitoring (LTMM) está disponible en PhysioNet [2], [3] y proviene del estudio de Weiss et al. [1]. Además de los registros de tres días, incluye una carpeta llamada LabWalks con caminatas de laboratorio de aproximadamente un minuto, hechas a una velocidad cómoda elegida por cada persona. Durante la caminata, un sensor inercial ubicado en la zona lumbar registró seis canales a 100 Hz: la aceleración vertical, mediolateral y anteroposterior (en g) y la velocidad angular en los ejes yaw, pitch y roll (en °/s).

Los 73 registros de LabWalks se descargaron con LabWalks Explorer, una aplicación desarrollada para este proyecto. Cada registro tiene un archivo de encabezado (.hea), con la edad y el sexo de la persona, y un archivo binario (.dat) con las muestras. La etiqueta se obtiene del nombre del archivo: los registros co corresponden a 38 personas que no caen, y los registros fl, a 35 personas con dos o más caídas en el año previo. Se trata, por lo tanto, de una etiqueta retrospectiva. La base incluye también una planilla clínica con pruebas como el TUG, que se pudo asociar a 69 de los 73 registros.

B. CASIA Gait Database

La base CASIA, del Instituto de Automatización de la Academia China de Ciencias, contiene siluetas de personas caminando, ya separadas del fondo. Se descargaron sus tres bases desde la página oficial del Center for Biometrics and Security Research [4], y sus características se resumen en la Tabla I. CASIA no tiene etiquetas de riesgo de caída, por lo que no se usará para entrenar el clasificador. Su función en el proyecto es preparar la Etapa 2, ya que permite probar la medición de la marcha desde imágenes con distintos ángulos de cámara, ropa, carga, velocidades e iluminación.

TABLA I. Bases de CASIA Gait Database usadas en el proyecto

Base	Personas	Qué varía	Secuencias por persona	Ref.
A	20	Ángulo de cámara (0°, 45° y 90°)	12	[5]
B	124	Ángulo de cámara (0° a 180°, cada 18°), bolso y abrigo	110	[6]
C	153	Velocidad y bolso, de noche con cámara infrarroja	10	[7]

III. Metodología

A. Herramientas

Todo el procesamiento se hizo en Python con notebooks de Jupyter. Se usaron las librerías wfdb para leer los registros de PhysioNet, SciPy para el filtrado y las pruebas estadísticas, pandas para las tablas, OpenCV para las imágenes de CASIA y Matplotlib para los gráficos. Se preparó un notebook para LTMM y otro para CASIA. Para que los resultados sean reproducibles, todos los parámetros están al inicio de cada notebook, se fijó una semilla aleatoria (42) y cada notebook se ejecuta completo de principio a fin. El trabajo se versiona en un repositorio de GitHub.

B. Control de calidad de LTMM

Antes de limpiar las señales se revisó cada registro con criterios objetivos. Se excluiría un registro si tuviera datos faltantes, algún canal plano (sensor desconectado) o menos de 20 s útiles. Además se marcarían, sin excluirlos, los registros con una frecuencia de muestreo distinta de 100 Hz, con más de un 1 % de muestras saturadas o con un promedio del eje vertical fuera del rango de 0,8 a 1,2 g, lo que indicaría un sensor girado. Por último, después de detectar los pasos (Sección III-D), se excluiría todo registro al que

se le descartara más del 20 % de sus intervalos entre pasos, porque eso indica que la detección no funcionó y que sus variables no son confiables.

C. Limpieza de las señales

La limpieza se hizo en tres pasos. Primero se recortaron 3 s al inicio y al final de cada caminata, porque corresponden al arranque y al frenado. Luego se aplicó un filtro Butterworth pasa bajo de cuarto orden, con frecuencia de corte de 20 Hz, aplicado hacia adelante y hacia atrás para no desfasar la señal. La marcha tiene casi toda su energía bajo 15 Hz, por lo que lo que queda sobre 20 Hz se considera ruido. Por último, se restó el promedio de la aceleración vertical para eliminar el efecto de la gravedad.

D. Variables de marcha

Con un solo sensor en la zona lumbar no se puede medir directamente la velocidad ni el largo de paso. Por eso se calcularon variables que sí se pueden obtener de forma confiable desde el tronco, agrupadas en la Tabla II. Los pasos se detectaron como los máximos de la aceleración vertical, suavizada con un filtro de 3 Hz y separados por al menos 0,3 s. Cuando la persona se detiene o gira, el detector puede juntar dos pasos o contar uno de más, por lo que antes de calcular las variables temporales se descartaron los intervalos entre pasos menores a 0,5 o mayores a 1,5 veces la mediana de cada persona. La regularidad y la simetría se calcularon con el método de autocorrelación de Moe-Nilssen y Helbostad [8], y las variables frecuenciales siguen a Weiss et al. [1]. La variabilidad se expresó como coeficiente de variación (CV), porque se ha asociado al riesgo de caída [9]. El número de pasos se conservó solo como dato descriptivo, porque depende de la duración del registro y no de la forma de caminar.

TABLA II. Variables de marcha calculadas para cada persona

Grupo	Variables	Cantidad
Temporales	Cadencia, tiempo de paso y de zancada, y CV de ambos tiempos	5
Regularidad	Regularidad de paso, regularidad de zancada y simetría	3
Frecuenciales	Frecuencia dominante, amplitud y ancho del pico del espectro de la aceleración vertical	3
Intensidad	Valor RMS de los tres ejes de aceleración y de los tres ejes del giroscopio	6
Total		17

Con pocas personas conviene no repetir información en las entradas de los modelos. Por eso se recorrieron las variables en el orden de la Tabla II y se descartó cada variable cuya correlación de Spearman con alguna ya elegida fuera mayor a 0,9 en valor absoluto. Las variables elegidas se guardaron en una tabla aparte, que será la entrada de los modelos de la sub-etapa 1.3.

E. Análisis estadístico

Cada variable se comparó entre quienes caen y quienes no caen con la prueba de Mann-Whitney [10], que no supone que los datos tengan distribución normal y es adecuada para muestras pequeñas. El tamaño del efecto se expresó como correlación biserial de rangos r, en la que 0,1 es un efecto pequeño, 0,3 uno mediano y 0,5 uno grande. Como se compararon 17 variables a la vez, los valores p se corrigieron con el método de Holm [11], para evitar que alguna diferencia aparezca como significativa solo por azar. También se compararon la edad y el sexo de ambos grupos, y se revisaron la correlación de Spearman entre variables y un análisis de componentes principales (PCA).

F. Revisión de CASIA

En CASIA se hizo un inventario de todas las secuencias, reconociendo en el nombre de cada carpeta la persona, la condición y el ángulo, y se comparó con el diseño de cada base para detectar faltantes. En una muestra de 200 secuencias por base se midió qué fracción de cada imagen ocupa la silueta, para detectar cuadros vacíos. Finalmente, en la vista lateral se midió en cada cuadro el ancho de la mitad inferior de la silueta, que crece y decrece con cada paso. Con la autocorrelación de esa señal se obtuvo el período de un paso y, a 25 cuadros por segundo, la cadencia.

IV. Resultados

A. Calidad y descripción de la muestra

Ningún registro de LTMM tuvo datos faltantes, canales planos, saturación ni problemas de orientación. En cambio, al registro fl015 se le descartó el 28 % de sus intervalos entre pasos. Al revisar su señal se vio que era varias veces más débil que la de las demás caminatas, que duraba 162 s en vez de alrededor de un minuto y que no mostraba un patrón de pasos, por lo que el detector estaba marcando ruido. Este registro se excluyó y la muestra quedó en 72 personas: 38 que no caen y 34 que caen. En el resto de los registros se descartó en promedio el 1,1 % de los intervalos, con un máximo de 16 %. La duración útil media fue de 43,5 s, con un rango de 24 a 114 s.

La Tabla III describe ambos grupos; la edad faltaba en dos encabezados y el sexo en uno. No hay diferencias de edad ni de sexo entre los grupos, de modo que estas variables no explicarían las diferencias de marcha encontradas. En cambio, los registros de quienes caen duran en promedio 9,4 s más.

TABLA III. Descripción de la muestra de LTMM

	No cae	Cae	p
Personas	38	34	–
Edad (años), media ± DE	78,6 ± 4,9	77,6 ± 5,0	0,533
Mujeres	24 (63,2 %)	21 (61,8 %)	1,000
Duración útil media (s)	39,1	48,5	–

B. Diferencias entre grupos

La Tabla IV muestra las variables con mayor diferencia entre grupos, y la Fig. 1 resume el tamaño del efecto de todas ellas. La única variable de marcha con una diferencia significativa después de la corrección de Holm fue la frecuencia dominante de la aceleración vertical, menor en quienes caen (1,78 Hz frente a 1,93 Hz; r = −0,49). Como la frecuencia dominante corresponde aproximadamente al número de pasos por segundo, este resultado indica que quienes caen dan pasos más lentos.

Otras variables muestran efectos medianos en la misma dirección. Quienes caen tienen una menor cadencia (109 frente a 115 pasos/min) y tiempos de paso y de zancada más largos; en el tiempo de zancada (1,10 frente a 1,04 s) el valor p corregido quedó muy cerca del límite (0,053). También muestran una menor intensidad del movimiento del tronco, con valores RMS más bajos en la aceleración anteroposterior y en la velocidad angular en yaw, aunque sin diferencias significativas tras la corrección. La regularidad del paso fue algo menor en quienes caen (0,73 frente a 0,77), y la variabilidad y la simetría no mostraron diferencias.

TABLA IV. Variables con mayor diferencia entre grupos (medianas)

Variable	No cae	Cae	r	p	p Holm
Frecuencia dominante (Hz)	1,93	1,78	−0,49	0,0004	0,007
Tiempo de zancada (s)	1,044	1,102	0,40	0,003	0,053
Cadencia (pasos/min)	114,7	108,9	−0,40	0,059	0,004
Tiempo de paso (s)	0,523	0,551	0,40	0,059	0,004
RMS aceleración AP (g)	0,157	0,137	−0,34	0,013	0,173
RMS giro yaw (°/s)	28,0	25,6	−0,32	0,021	0,253
Amplitud dominante (g^2/Hz)	0,130	0,099	−0,31	0,025	0,277
Regularidad de paso	0,772	0,728	−0,25	0,067	0,535
CV tiempo de paso (%)	7,34	7,66	0,09	0,524	1,000

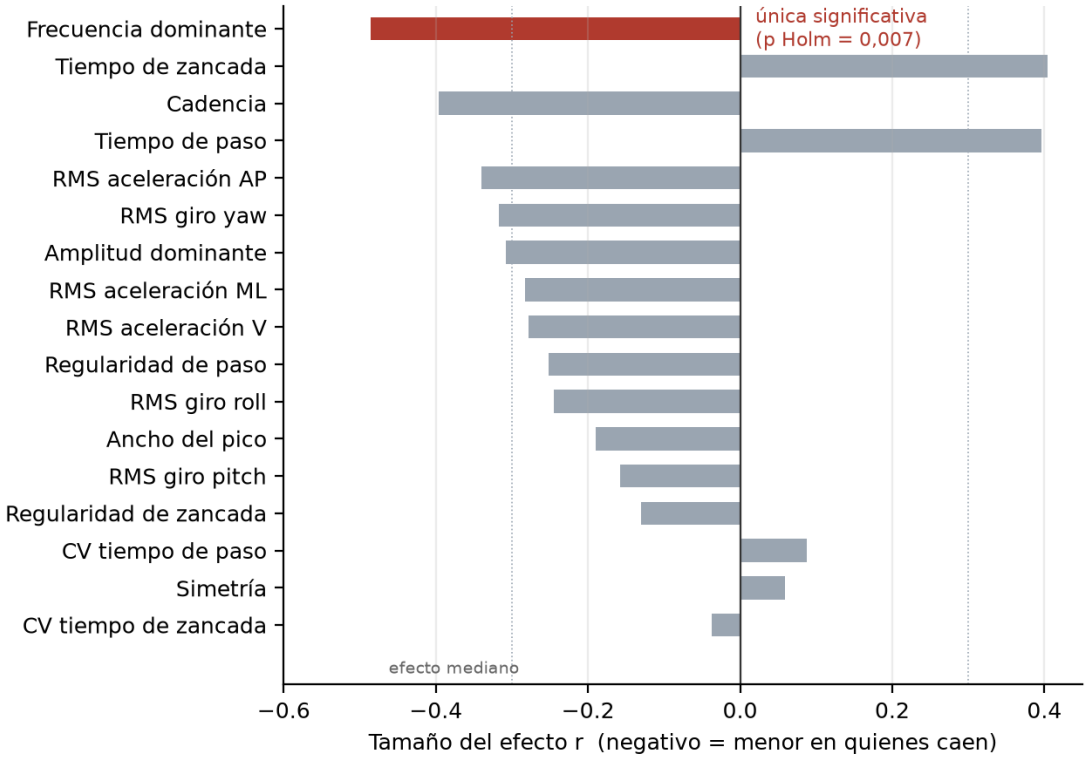


Fig. 1. Tamaño del efecto (r) de cada variable al comparar a quienes caen con quienes no caen. Los valores negativos indican valores menores en quienes caen, y las líneas punteadas marcan un efecto mediano (|r| = 0,3). No se incluye el número de pasos (ver Sección V).

C. Relación entre variables

El análisis de correlación de Spearman mostró dos grupos de variables que entregan casi la misma información (|r| > 0,9): la cadencia, el tiempo de paso y el tiempo de zancada (|r| = 1,00), y la amplitud dominante con el RMS de la aceleración vertical (r = 0,94). Al conservar una variable de cada grupo se descartaron el tiempo de paso, el tiempo de zancada y el RMS de la aceleración vertical, y quedaron 14 variables para los modelos. En el PCA, las dos primeras componentes explican el 39 % y el 20 % de la varianza, y los dos grupos aparecen muy superpuestos.

D. CASIA Gait Database

La Tabla V resume el inventario de CASIA. Las bases A y C están completas, y a la base B le faltan 47 secuencias repartidas en 8 personas, un 0,3 % del total. No hubo carpetas sin reconocer ni secuencias repetidas. La mediana de cuadros por secuencia fue de 82 en A, 80 en B y 63 en C, es decir, entre 2,5 y 3,3 s de video. Se encontraron 59 secuencias con menos de 20 cuadros, demasiado cortas para contener un ciclo de marcha completo. La segmentación es de buena calidad: en la muestra revisada, los cuadros vacíos fueron el 0 % en A, el 0,09 % en B y el 0,02 % en C.

TABLA V. Inventario de CASIA Gait Database

Base	Personas	Secuencias	% de lo esperado	Cuadros	Tamaño de imagen
A	20	240	100	19 135	352 × 240
B	124	13 593	99,7	1 118 373	320 × 240
C	153	1 530	100	100 346	320 × 240

La Fig. 2 muestra la cadencia estimada desde las siluetas en vista lateral. Con marcha normal se obtuvieron valores entre 115 y 125 pasos/min, que son razonables para adultos. En la base C, que incluye cambios de velocidad, la cadencia fue de 94 pasos/min al caminar lento, 115 al caminar normal y 125 al caminar rápido. Esto muestra que el método detecta cambios reales en la marcha.

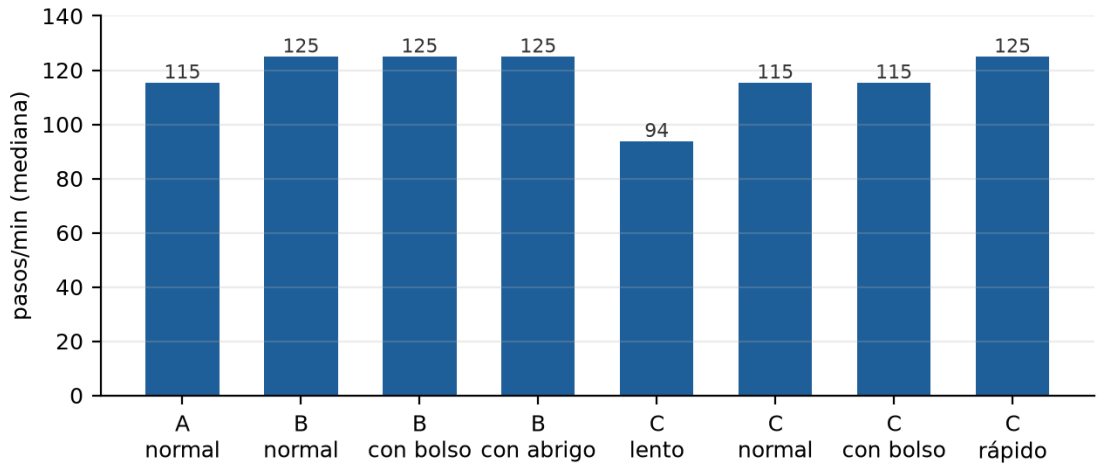


Fig. 2. Cadencia mediana estimada desde las siluetas de CASIA en vista lateral, según base y condición.

V. Discusión

El resultado principal es que, en caminatas cortas de laboratorio, quienes caen caminan con un ritmo más lento que quienes no caen. Esto concuerda con la literatura revisada en el marco teórico, donde la velocidad y los parámetros temporales de la marcha aparecen entre las variables más asociadas al riesgo de caída. Con los mismos participantes, Weiss et al. [1] encontraron que la regularidad de la marcha en la vida diaria diferenciaba a ambos grupos. En las caminatas de laboratorio esa diferencia es pequeña, lo que es esperable, porque una caminata breve en un pasillo es más uniforme que la marcha del día a día.

Dos resultados deben interpretarse con cuidado. En una primera versión del análisis, el número de pasos apareció como la variable con mayor diferencia (68 frente a 81 pasos; r = 0,53), pero esto se debía a que los registros de quienes caen son más largos, no a su forma de caminar, por lo que se dejó fuera. En esa misma versión, el coeficiente de variación del tiempo de paso llegó hasta 206 % en algunos registros, un valor que no es fisiológico y que aparece cuando la persona se detiene o gira. Al descartar los intervalos

anómalos, el CV quedó entre 3,4 % y 27,6 %, pero siguió sin mostrar diferencias entre grupos (7,3 % frente a 7,7 %; p = 0,524). Es decir, en estas caminatas cortas la variabilidad no distingue a quienes caen. Esta misma revisión permitió detectar el registro fl015, cuya señal no mostraba un patrón de pasos y que se excluyó del análisis.

Finalmente, la superposición de los grupos en el PCA y el hecho de que solo una variable sea significativa anticipan que la clasificación no será sencilla. Con 72 personas y 14 variables existe riesgo de sobreajuste, por lo que en la sub-etapa 1.3 será importante validar separando por sujeto [12].

VI. Decisiones y limitaciones

A partir de estos resultados se tomaron las siguientes decisiones, que ya están aplicadas en el notebook salvo la última, que corresponde a la Etapa 2:

- **Registro fl015.** Se excluyó porque se le descartó el 28 % de sus intervalos entre pasos y su señal no mostraba un patrón de pasos. Queda registrado, con su motivo, en el archivo de control de calidad.
- **Número de pasos.** Se dejó fuera de las variables de marcha, porque depende de la duración del registro; se conserva solo como dato descriptivo.
- **Variabilidad.** Se descartaron los intervalos entre pasos anómalos, causados por pausas o giros, y se volvió a calcular el CV. En promedio se descartó el 1,1 % de los intervalos de cada registro.
- **Variables redundantes.** Se conservó una sola variable de cada grupo muy correlacionado: la cadencia en vez del tiempo de paso y el de zancada, y la amplitud dominante en vez del RMS de la aceleración vertical. Quedaron 14 variables.
- **Uso de CASIA.** No se usará para entrenar, sino para probar en la Etapa 2 la estimación de pose con MediaPipe [13]. Se excluirán las 59 secuencias con menos de 20 cuadros.

Las principales limitaciones son que las etiquetas de LTMM son retrospectivas, que la muestra es pequeña y que un solo sensor lumbar no permite medir la velocidad ni el largo de paso. En CASIA, las personas son en su mayoría jóvenes y sanas, y la cadencia medida desde la silueta solo puede tomar algunos valores, porque el período se mide en cuadros enteros.

VII. Productos y próximos pasos

La Tabla VI lista los productos de esta sub-etapa, que están disponibles en el repositorio del proyecto.

TABLA VI. Productos de la sub-etapa 1.2

Archivo	Contenido
notebooks/01_EDA_LabWalks.ipynb	Carga, control de calidad, limpieza, variables y EDA de LTMM
notebooks/02_EDA_CASIA.ipynb	Inventario, completitud, calidad y cadencia de CASIA A, B y C
datos/procesados/labwalks_variables.csv	Dataset limpio: una fila por cada una de las 72 personas, con etiqueta, datos clínicos y 17 variables de marcha
datos/procesados/labwalks_modelo.csv	Entrada de los modelos: etiqueta y las 14 variables no redundantes
DICCIONARIO_DE_DATOS.md	Descripción de cada columna, sus unidades y los pasos de limpieza
datos/procesados/casia_*.csv	Inventario, calidad y cadencia de CASIA
figuras/*.png	Gráficos del análisis exploratorio

El siguiente paso es la sub-etapa 1.3, en la que se entrenarán y compararán los modelos Random Forest, XGBoost y LSTM. Los dos primeros usarán la tabla labwalks_modelo.csv y la LSTM, las señales limpias. Se usará validación cruzada por sujeto y se reportarán exactitud, sensibilidad, F1-score y AUC.

Referencias

[1] A. Weiss, M. Brozgol, M. Dorfman, T. Herman, S. Shema, N. Giladi, and J. M. Hausdorff, "Does the evaluation of gait quality during daily life provide insight into fall risk? A novel approach using 3-day accelerometer recordings," Neurorehabil. Neural Repair, vol. 27, no. 8, pp. 742–752, 2013, doi: 10.1177/1545968313491004.

[2] J. M. Hausdorff, "Long Term Movement Monitoring Database," version 1.0.0, PhysioNet, 2016, doi: 10.13026/C2S59C.

[3] A. L. Goldberger et al., "PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals," Circulation, vol. 101, no. 23, pp. e215–e220, Jun. 2000, doi: 10.1161/01.CIR.101.23.e215.

[4] Center for Biometrics and Security Research, Institute of Automation, Chinese Academy of Sciences, "CASIA Gait Database." [En línea]. Disponible: http://www.cbsr.ia.ac.cn/english/Gait%20Databases.asp (accedido: 21 oct. 2026).

[5] L. Wang, T. Tan, H. Ning, and W. Hu, "Silhouette analysis-based gait recognition for human identification," IEEE Trans. Pattern Anal. Mach. Intell., vol. 25, no. 12, pp. 1505–1518, Dec. 2003.

[6] S. Yu, D. Tan, and T. Tan, "A framework for evaluating the effect of view angle, clothing and carrying condition on gait recognition," in Proc. 18th Int. Conf. Pattern Recognit. (ICPR), Hong Kong, China, 2006, vol. 4, pp. 441–444, doi: 10.1109/ICPR.2006.67.

[7] D. Tan, K. Huang, S. Yu, and T. Tan, "Efficient night gait recognition based on template matching," in Proc. 18th Int. Conf. Pattern Recognit. (ICPR), Hong Kong, China, 2006, vol. 3, pp. 1000–1003.

[8] R. Moe-Nilssen and J. L. Helbostad, "Estimation of gait cycle characteristics by trunk accelerometry," J. Biomech., vol. 37, no. 1, pp. 121–126, 2004, doi: 10.1016/S0021-9290(03)00233-1.

[9] J. M. Hausdorff, D. A. Rios, and H. K. Edelberg, "Gait variability and fall risk in community-living older adults: A 1-year prospective study," Arch. Phys. Med. Rehabil., vol. 82, no. 8, pp. 1050–1056, Aug. 2001, doi: 10.1053/apmr.2001.24893.

[10] H. B. Mann and D. R. Whitney, "On a test of whether one of two random variables is stochastically larger than the other," Ann. Math. Statist., vol. 18, no. 1, pp. 50–60, 1947.

[11] S. Holm, "A simple sequentially rejective multiple test procedure," Scand. J. Statist., vol. 6, no. 2, pp. 65–70, 1979.

[12] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," GigaScience, vol. 6, no. 5, Art. no. gix019, May 2017, doi: 10.1093/gigascience/gix019.

[13] V. Bazarevsky, I. Grishchenko, K. Raveendran, T. Zhu, F. Zhang, and M. Grundmann, "BlazePose: On-device real-time body pose tracking," 2020, arXiv:2006.10204.