Clasificación del riesgo de caída en adultos mayores mediante análisis de marcha y aprendizaje automático: avance de la sub-etapa 1.3, implementación y entrenamiento de modelos, con registros de vida diaria

Versión 3 (3 de noviembre de 2026). Incorpora las observaciones de la revisión del profesor guía del 1 de noviembre. Repositorio: github.com/diegobustos-code/proyecto-marcha-practicaI.

***Resumen*: Este documento presenta el avance de la sub-etapa 1.3 del proyecto, correspondiente a las semanas 6 a 9. Con el dataset limpio de la sub-etapa 1.2 (72 personas de la base LTMM) se implementaron y entrenaron los tres modelos comprometidos: Random Forest y XGBoost, que usan 14 variables de marcha, y una red neuronal LSTM con dos capas convolucionales previas, que usa directamente las señales del sensor. Los modelos se evaluaron con validación cruzada estratificada y repetida, separando siempre por persona, y se compararon con tres referencias simples. Random Forest obtuvo un AUC de 0,68 ± 0,14 y XGBoost de 0,64 ± 0,15, mientras que la LSTM quedó cerca del azar (0,55 ± 0,15) por un sobreajuste marcado. El mejor resultado lo obtuvo una regresión logística con una sola variable, la frecuencia dominante de la marcha (AUC 0,75 ± 0,13), numéricamente mayor que el de la prueba clínica TUG (0,66 ± 0,14), aunque sin una diferencia significativa. Con 72 personas, el desempeño empeora a medida que aumenta la complejidad del modelo. Como extensión, se procesaron los registros de tres días de vida diaria de la misma base: se detectaron 3741 tramos de marcha válidos en 70 personas y se entrenaron los mismos modelos con esas variables y con ambas fuentes combinadas. La vida diaria no mejoró la clasificación (AUC entre 0,60 y 0,64 en los modelos), aunque mostró que la variabilidad de la marcha en el laboratorio casi no se relaciona con la de la vida diaria. Los modelos quedaron guardados y documentados en notebooks reproducibles.**

***Palabras clave*: riesgo de caída, análisis de marcha, Random Forest, XGBoost, LSTM, validación cruzada, sobreajuste, vida diaria.**

I. Introducción

La sub-etapa 1.3 tiene como objetivo implementar y entrenar los tres modelos de aprendizaje automático definidos en el proyecto: Random Forest [3], XGBoost [4] y LSTM [5]. El producto comprometido es un notebook reproducible con los tres modelos entrenados, versionado en un repositorio de GitHub.

El trabajo parte del dataset limpio de la sub-etapa 1.2, obtenido de las caminatas de laboratorio de la base Long Term Movement Monitoring (LTMM) [1], [2]. Tras el control de calidad quedaron 72 personas: 38 que no caen y 34 con dos o más caídas en el año previo. Para cada persona se dispone de 14 variables de marcha no redundantes y de sus señales limpias de seis canales. La base CASIA no se usó en esta sub-etapa porque no tiene etiquetas de caída; se reserva para validar la estimación de pose en la Etapa 2.

Como el principal límite resultó ser la poca marcha disponible por persona, se agregó una extensión: los registros de tres días de vida diaria de LTMM, en los que las mismas personas llevaron el sensor durante su rutina normal [1]. Con ellos se repitió el entrenamiento para responder una pregunta adicional: ¿la marcha de la vida diaria distingue mejor a quienes caen que una caminata de un minuto en el laboratorio?

El documento se organiza así. La Sección II describe la metodología. La Sección III presenta los resultados y la Sección IV los discute, incluida la extensión con registros de vida diaria. La Sección V resume las limitaciones y los próximos pasos, y la Sección VI, los productos entregados.

II. Metodología

A. Validación

Con solo 72 personas, una única división entre entrenamiento y prueba daría un resultado que depende mucho de qué personas quedan en cada grupo. Por eso se usó validación cruzada estratificada de 5 partes: los datos se dividen en 5 grupos con la misma proporción de personas que caen, se entrena con 4 y se prueba con el restante, rotando hasta usar cada grupo una vez. Para Random Forest, XGBoost y las referencias, este proceso se repitió 10 veces con un orden distinto, lo que da 50 pruebas por modelo. La LSTM, mucho más lenta de entrenar, se evaluó con 3 repeticiones (15 pruebas), usando exactamente las mismas particiones que las primeras 15 de los otros modelos, lo que permite compararlos en igualdad de condiciones.

Las personas de prueba nunca se usan durante el entrenamiento, como recomiendan Saeb et al. [8]. En la tabla de variables cada persona aparece una sola vez, por lo que la separación por persona es automática; en la LSTM, todas las ventanas de una persona quedan siempre del mismo lado. Los pasos que aprenden algo de los datos, como completar valores faltantes o normalizar las señales, se calcularon solo con los datos de entrenamiento de cada partición. Se reportan exactitud, sensibilidad, especificidad, F1-score y AUC, como promedio ± desviación estándar de las pruebas.

B. Puntos de comparación

Un modelo solo es útil si supera a alternativas más simples. Por eso se incluyeron tres referencias: un clasificador sin modelo, que responde siempre la clase más frecuente (AUC 0,5); una regresión logística con una sola variable, la frecuencia dominante, que fue la única con diferencia significativa en el análisis exploratorio; y una regresión logística con el resultado de la prueba Timed Up and Go (TUG) de la planilla clínica, disponible en 68 de las 72 personas. A las 4 personas sin TUG se les asignó la mediana de las personas de entrenamiento de cada partición, dentro del pipeline, para no usar información de prueba. Como control, en la sub-etapa 1.4 (notebook 05b) el TUG se comparó también solo con las 68 personas que tienen el dato, sin completar nada, y el resultado fue similar (AUC 0,68).

C. Random Forest y XGBoost

Ambos modelos usan árboles de decisión y reciben las 14 variables de marcha. Random Forest entrena muchos árboles independientes y decide por votación [3]; XGBoost construye los árboles uno tras otro, de modo que cada uno corrige los errores de los anteriores [4]. Se eligieron parámetros conservadores, pensados para pocos datos, que se resumen en la Tabla I. Su ajuste fino queda para la sub-etapa 1.4.

TABLA I. Parámetros de Random Forest y XGBoost

Modelo	Parámetro	Motivo
Random Forest	500 árboles	Resultado estable entre ejecuciones
Random Forest	Mínimo 2 personas por hoja	Evita que los árboles memoricen casos aislados
Random Forest	Pesos de clase equilibrados	Mismo peso a quienes caen y no caen
XGBoost	300 árboles, tasa de aprendizaje 0,05	Muchos árboles pequeños que aprenden de a poco
XGBoost	Profundidad máxima 3	Árboles simples, adecuados para pocos datos
XGBoost	80 % de personas y variables por árbol	Reduce el sobreajuste

D. Red CNN + LSTM

A diferencia de los otros modelos, la LSTM recibe directamente las señales del sensor. Para aumentar el número de ejemplos, cada caminata se cortó en ventanas de 5 s, a 50 Hz y con los seis canales, traslapadas a la mitad. Así se obtuvieron 1150 ventanas (entre 8 y 44 por persona, con una mediana de 15). Cada ventana lleva la etiqueta de su persona, y la probabilidad de caer de una persona se calcula como el promedio de sus ventanas.

En una prueba previa con datos simulados, una LSTM sola sobre las señales crudas no lograba aprender. Por eso se antepusieron dos capas convolucionales, que detectan patrones cortos de la señal y la resumen antes de que la lea la LSTM, siguiendo la arquitectura que usaron Kiprijanovska et al. [6] y Alqurashi et al. [7]. La red completa tiene dos convoluciones de 16 y 32 filtros, una LSTM de 32 unidades y dos capas de salida, con un total de 12 081 parámetros. Se entrenó con el optimizador Adam, una tasa de aprendizaje de 0,001 y dropout de 0,3. Un 20 % de las personas de entrenamiento se apartó para decidir cuándo detener el entrenamiento: la red entrena al menos 40 épocas y se detiene si la pérdida de validación no mejora en 20, conservando la mejor versión.

El modelo final que se guardó como checkpoint se entrenó con el mismo procedimiento, pero con todas las personas: se apartó igualmente un 20 % (unas 14 personas) para elegir la mejor época, la red entrenó 40 épocas y se guardaron los pesos de la época con menor pérdida de validación. Lo mismo ocurrió con las tres fuentes de datos. Hay que reconocer que este mecanismo de parada es poco confiable con tan pocas personas: en la validación cruzada, el 20 % de entrenamiento son unas 11 personas, y el mínimo de 40 épocas obliga a seguir entrenando mucho después de la mejor época, que estuvo entre la 2 y la 4.

E. Herramientas y reproducibilidad

Los modelos se implementaron en Python con scikit-learn [9], XGBoost [4] y PyTorch [10]. Se eligió PyTorch en lugar de TensorFlow porque este último todavía no tiene versión para Python 3.14. Todos los

procesos usan la semilla aleatoria 42 y cada notebook se ejecuta completo de principio a fin. Al terminar, cada modelo se entrenó con todas las personas y se guardó como checkpoint junto con un archivo que registra sus variables de entrada, parámetros, métricas de validación y versiones de las librerías.

F. Extensión con registros de vida diaria

Los registros de tres días duran entre 47 y 75 horas por persona, con los mismos seis canales a 100 Hz, y pesan en total unos 20 GB. Como la marcha está mezclada con reposo, sueño y otras actividades, primero se buscaron los tramos en que la persona camina. Cada archivo se leyó por bloques de una hora y la aceleración vertical se recorrió en trozos de 5 s traslapados a la mitad. Un trozo se consideró marcha si cumplía tres condiciones: suficiente movimiento, energía concentrada en el ritmo de los pasos y pasos que se repiten (Tabla II). Los trozos de marcha seguidos se unieron en tramos y solo se usaron los de al menos 30 s.

TABLA II. Condiciones del detector de tramos de marcha

Condición	Qué mide	Umbral inicial	Umbral calibrado
Movimiento	Desviación estándar de la aceleración vertical	0,060 g	0,054 g
Ritmo de pasos	Fracción de la energía entre 0,6 y 3 Hz	0,50	0,29
Repetición	Pico de autocorrelación entre 0,3 y 1,2 s	0,40	0,30

Los umbrales iniciales se fijaron con valores típicos de la literatura. Para comprobarlos, el detector se aplicó a las caminatas de laboratorio, donde se sabe que la persona camina todo el tiempo: solo el 62 % de esos trozos se reconoció como marcha, y 27 de las 73 caminatas quedaron bajo el 80 %. La condición que más fallaba era el ritmo de pasos, que solo cumplía el 64 % de los trozos. Por eso los umbrales se calibraron con esas mismas caminatas: cada umbral se bajó hasta dejar pasar el 95 % de la marcha conocida, con un mínimo de seguridad que no se alcanzó. La calibración solo puede relajar los umbrales, nunca endurecerlos.

A cada tramo se le aplicaron exactamente las mismas funciones de limpieza y las mismas variables de la sub-etapa 1.2, y se descartaron los tramos con menos de 10 pasos o más del 20 % de intervalos anómalos, un segundo filtro contra movimientos que no son marcha. Cada persona se resumió con la mediana de sus tramos válidos y se le agregaron dos medidas de actividad: minutos de marcha por día y duración media de los tramos. Se excluyeron las personas con menos de 5 tramos válidos. Con la misma regla de redundancia de la sub-etapa 1.2 se generaron dos tablas de entrada: solo vida diaria (16 variables) y combinada, con las variables de laboratorio y de vida diaria de las personas presentes en ambas bases (30 variables). Para la LSTM se guardaron hasta 10 minutos de tramos válidos por persona y se usaron como máximo 60 ventanas por persona, para que quienes caminan más no dominaran el entrenamiento. Los modelos, la validación y las referencias fueron los mismos de las secciones A a D.

Como las fuentes no tienen exactamente a las mismas personas, cada registro se identificó por los cinco primeros caracteres de su nombre (por ejemplo, co028), que corresponden al código de la persona. Tres

archivos de tres días tienen un sufijo en el nombre (CO028_n, CO029_n y CO038_2); con esta regla, cada uno quedó asignado a una sola persona y ninguna persona aparece dos veces, por lo que no hay fuga de información entre particiones. La Tabla III resume quién está en cada fuente. En las 62 personas que están en ambas, la etiqueta de caída es la misma en las dos bases.

TABLA III. Correspondencia de personas entre las fuentes de datos

Fuente	Archivos	Excluidos	Personas en el modelo
Caminatas de laboratorio	73	fl015 (control de calidad)	72 (38 no caen, 34 caen)
Registros de tres días	71	FL035 (menos de 5 tramos válidos)	70 (40 no caen, 30 caen)
Combinado (personas en ambas fuentes)	—	10 solo en laboratorio y 8 solo en vida diaria	62

III. Resultados

A. Random Forest y XGBoost

La Tabla IV muestra los resultados de las 50 pruebas. Todos los modelos superaron a la referencia sin modelo. Random Forest obtuvo un AUC de 0,68 y XGBoost de 0,64, con sensibilidades de 0,60 y 0,55. Sin embargo, la regresión con solo la frecuencia dominante superó a ambos, con un AUC de 0,75 y la mayor exactitud (0,70). La prueba TUG fue la referencia más débil, con un AUC de 0,66 y una sensibilidad de solo 0,40.

TABLA IV. Resultados de Random Forest, XGBoost y las referencias (50 pruebas)

Modelo	Exactitud	Sensibilidad	Especificidad	F1	AUC
Sin modelo	0,53 ± 0,03	0,00 ± 0,00	1,00 ± 0,00	0,00 ± 0,00	0,50 ± 0,00
Solo frecuencia dominante	**0,70 ± 0,12**	0,60 ± 0,19	**0,80 ± 0,13**	**0,65 ± 0,15**	**0,75 ± 0,13**
Solo TUG	0,56 ± 0,13	0,40 ± 0,19	0,71 ± 0,20	0,45 ± 0,16	0,66 ± 0,14
Random Forest	0,61 ± 0,11	0,60 ± 0,17	0,61 ± 0,18	0,59 ± 0,12	0,68 ± 0,14
XGBoost	0,59 ± 0,13	0,55 ± 0,19	0,64 ± 0,19	0,55 ± 0,15	0,64 ± 0,15

Las desviaciones estándar son grandes (entre 0,13 y 0,15 en el AUC), lo que muestra que el resultado cambia bastante según qué personas quedan en la prueba. Las diferencias entre los modelos son menores que esa variación, por lo que deben confirmarse con una comparación formal en la sub-etapa 1.4.

B. LSTM

La LSTM obtuvo un AUC de 0,55 ± 0,15, apenas sobre el azar. Las curvas de aprendizaje (Fig. 1) explican este resultado: la pérdida de entrenamiento baja casi hasta cero, mientras que la de validación aumenta desde las primeras épocas. En las tres particiones graficadas, la mejor versión de la red fue la de las épocas 2 a 4, y en las 15 particiones el entrenamiento se detuvo en el mínimo de 40 épocas. Es decir, la red aprendió a reconocer a las personas de entrenamiento, pero lo aprendido no le sirvió para clasificar a personas nuevas.

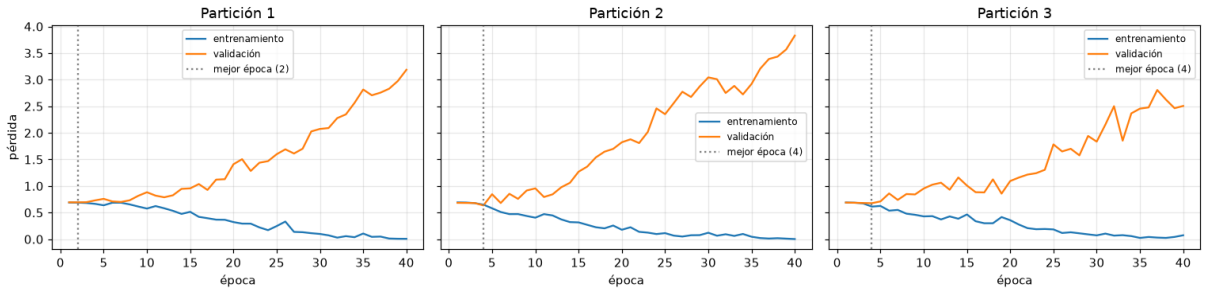


Fig. 1. Curvas de aprendizaje de la LSTM en las tres primeras particiones. La pérdida de entrenamiento baja mientras la de validación sube desde las primeras épocas, lo que indica sobreajuste. La línea punteada marca la mejor época.

C. Comparación de los tres modelos

La Tabla V y la Fig. 2 comparan todos los modelos en las mismas 15 particiones. El orden se mantiene: la frecuencia dominante sola obtuvo el mayor AUC (0,75), seguida de Random Forest (0,68), XGBoost (0,67), el TUG (0,66) y la LSTM (0,55). La LSTM tuvo además la sensibilidad más variable, entre 0 y 1 según la partición.

TABLA V. Comparación de los tres modelos en las mismas 15 pruebas

Modelo	Exactitud	Sensibilidad	Especificidad	F1	AUC
Sin modelo	0,53 ± 0,03	0,00 ± 0,00	1,00 ± 0,00	0,00 ± 0,00	0,50 ± 0,00
Solo frecuencia dominante	**0,71 ± 0,13**	0,60 ± 0,23	**0,80 ± 0,10**	**0,64 ± 0,19**	**0,75 ± 0,15**
Solo TUG	0,56 ± 0,12	0,39 ± 0,17	0,70 ± 0,22	0,45 ± 0,15	0,66 ± 0,13
Random Forest	0,64 ± 0,11	0,64 ± 0,17	0,65 ± 0,16	0,62 ± 0,12	0,68 ± 0,14
XGBoost	0,60 ± 0,10	0,58 ± 0,23	0,62 ± 0,19	0,56 ± 0,17	0,67 ± 0,13
LSTM	0,53 ± 0,07	0,58 ± 0,36	0,48 ± 0,38	0,47 ± 0,24	0,55 ± 0,15

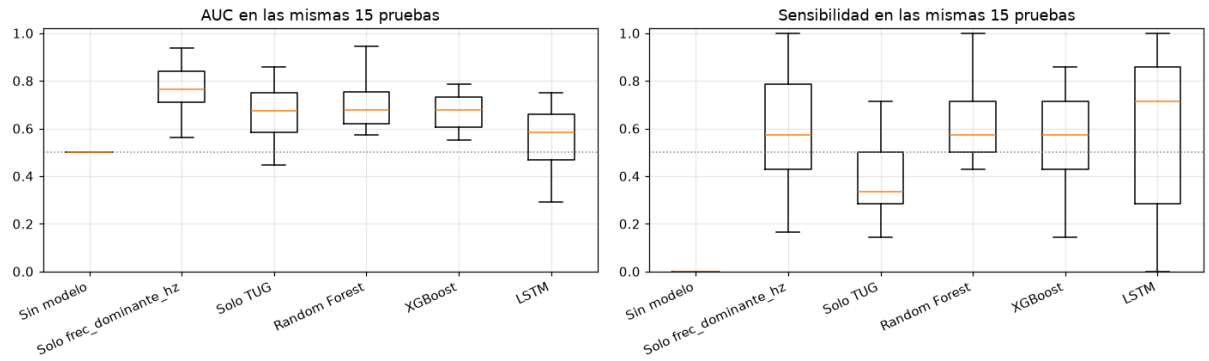


Fig. 2. AUC y sensibilidad de cada modelo en las mismas 15 pruebas de la validación cruzada. La línea punteada marca el nivel del azar (0,5).

D. Variables más importantes

En los modelos finales, entrenados con todas las personas, la variable más importante fue la frecuencia dominante, tanto en Random Forest como en XGBoost (Fig. 3). En Random Forest le siguieron la cadencia y la amplitud dominante. Es decir, los modelos complejos llegaron a la misma conclusión que el análisis exploratorio: el ritmo de la marcha es lo que más distingue a quienes caen.

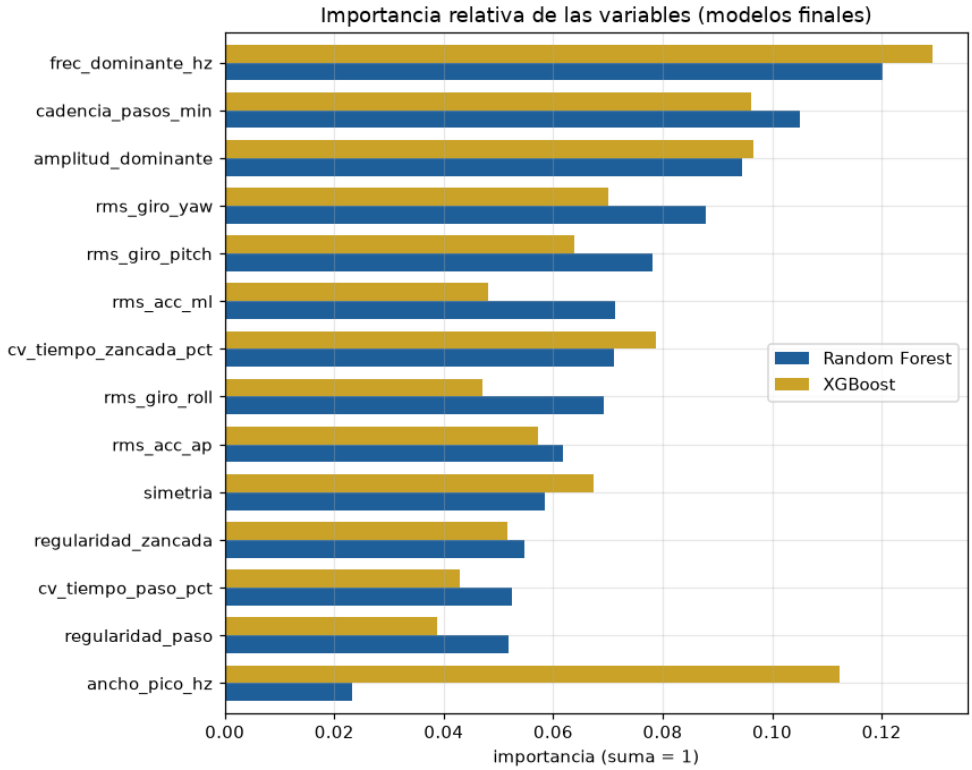


Fig. 3. Importancia relativa de las variables en los modelos finales de Random Forest y XGBoost (cada modelo suma 1).

E. Registros de vida diaria

Se procesaron los 71 registros disponibles, con una mediana de 74 horas cada uno. Con los umbrales calibrados, el detector reconoció como marcha el 89 % de los trozos de laboratorio y las caminatas bajo el 80 % bajaron de 27 a 8 (Fig. 4). Las que siguen fallando son en su mayoría de personas que caen, con una marcha más irregular. En la vida diaria se detectaron 3905 tramos de marcha, de los cuales 3741 (96 %) pasaron el control de calidad. Solo una persona se excluyó por tener menos de 5 tramos válidos, por lo que quedaron 70 personas: 40 que no caen y 30 que caen, con una mediana de unos 47 tramos por persona.

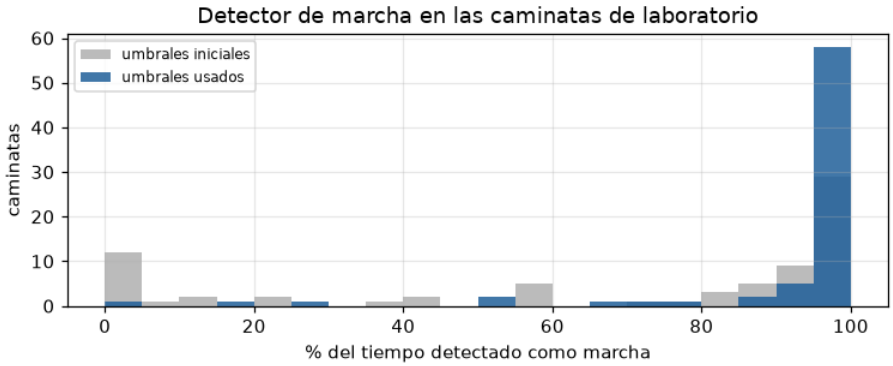


Fig. 4. Porcentaje de cada caminata de laboratorio reconocido como marcha por el detector, con los umbrales iniciales (gris) y con los umbrales calibrados (azul).

Quienes caen caminaron una mediana de 22,6 minutos al día y quienes no caen 28,1 minutos, una diferencia que no fue significativa. Ninguna variable de vida diaria mostró diferencias significativas entre grupos después de la corrección de Holm. Las mayores diferencias fueron una menor amplitud dominante ($r = -0{,}31$; p sin corregir = 0,025) y un menor movimiento de rotación ($r = -0{,}33$; p sin corregir = 0,020) en quienes caen, en la misma dirección que lo descrito por Weiss et al. [1]. Al comparar a las 62 personas presentes en ambas bases, las variables de ritmo se parecen bastante entre el laboratorio y la vida diaria (correlación de Spearman de 0,62 para la cadencia y 0,69 para la frecuencia dominante), pero las de variabilidad casi no se relacionan (0,18 a 0,21 para el coeficiente de variación del paso y la zancada).

La Tabla VI y la Fig. 5 comparan los modelos según los datos de entrada, en las mismas 15 particiones. Con la vida diaria, Random Forest y XGBoost obtuvieron un AUC de 0,60, por debajo del laboratorio, y combinar ambas fuentes tampoco mejoró el resultado (0,64 y 0,58). La LSTM subió levemente con la vida diaria (0,62), pero con una sensibilidad de solo 0,21. La frecuencia dominante de laboratorio siguió siendo la mejor referencia, mientras que la de vida diaria no distinguió a los grupos (AUC 0,38). Con las 50 pruebas de los notebooks de árboles los resultados fueron similares (Random Forest 0,62 en vida diaria y 0,62 combinado).

El AUC de 0,38, bajo el nivel del azar, no es un error de signo. En la vida diaria, la frecuencia dominante casi no cambia entre grupos (1,71 Hz en quienes caen frente a 1,76 Hz en quienes no). Cuando una variable no aporta información, la validación cruzada tiende a dar un AUC algo menor que 0,5: al sacar a unas personas para la prueba, el promedio de las que quedan en entrenamiento se corre en sentido contrario, y el modelo aprende una relación que en la prueba se invierte. Por la misma razón la sensibilidad fue casi nula (0,01). Este resultado debe leerse como «no distingue», no como una relación inversa.

TABLA VI. AUC y sensibilidad según los datos de entrada (mismas 15 pruebas)

Modelo	Laboratorio (72)	Vida diaria (70)	Combinado (62)
Solo frecuencia dominante	**0,75 ± 0,15 (0,60)**	0,38 ± 0,14 (0,01)	0,71 ± 0,12 (0,51)
Solo TUG	0,66 ± 0,13 (0,39)	0,61 ± 0,18 (0,27)	0,63 ± 0,11 (0,36)
Random Forest	0,68 ± 0,14 (0,64)	0,60 ± 0,22 (0,50)	0,64 ± 0,16 (0,57)
XGBoost	0,67 ± 0,13 (0,58)	0,60 ± 0,20 (0,50)	0,58 ± 0,12 (0,39)
LSTM	0,55 ± 0,15 (0,58)	0,62 ± 0,17 (0,21)	0,57 ± 0,15 (0,29)

Cada celda muestra el AUC promedio ± desviación estándar y, entre paréntesis, la sensibilidad promedio. Entre paréntesis en el encabezado se indica el número de personas.

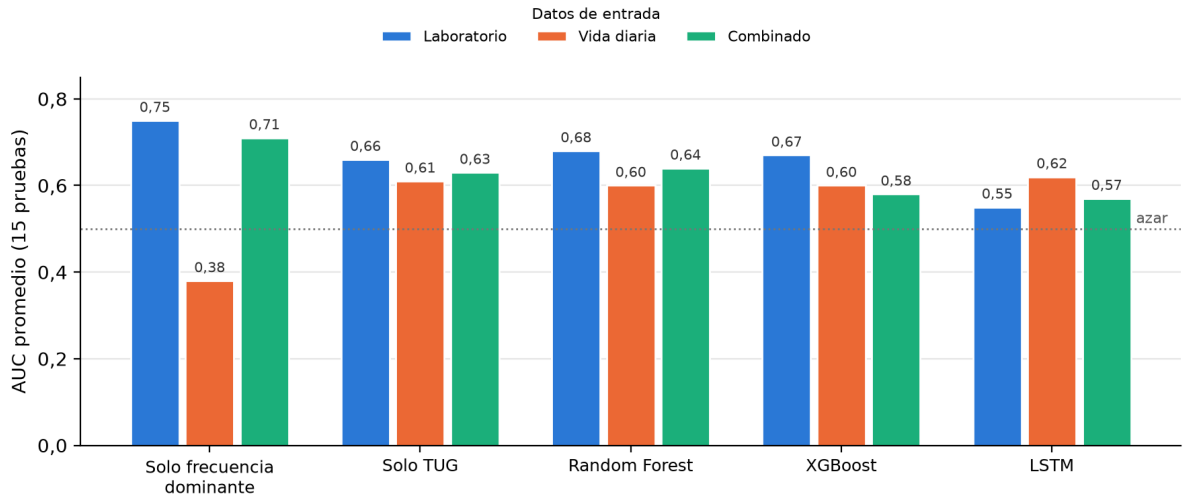


Fig. 5. AUC promedio de cada modelo según los datos de entrada, en las mismas 15 pruebas de la validación cruzada. La línea punteada marca el nivel del azar (0,5).

IV. Discusión

El resultado principal es que, en esta muestra, el desempeño empeora a medida que aumenta la complejidad del modelo: una sola variable supera a Random Forest y XGBoost, y estos superan a la LSTM. La explicación más probable es el sobreajuste. Con 72 personas, los modelos complejos aprenden también del ruido de las variables que casi no distinguen a los grupos, y la LSTM, con más de 12 000 parámetros, llega a memorizar a cada persona. Aunque las ventanas dan 1150 ejemplos, provienen de solo 72 personas, que es la cantidad real de casos independientes. Esto concuerda con la literatura revisada: el metaanálisis de Mou et al. [11] advierte que los estudios con menos de 100 participantes tienden a reportar resultados demasiado optimistas, y Alqurashi et al. [7] obtuvieron buenos resultados con redes LSTM usando 163 personas.

La frecuencia dominante obtuvo un AUC mayor que la prueba TUG (0,75 frente a 0,66), aunque en la sub-etapa 1.4 esa diferencia no resultó significativa. Es coherente con la capacidad limitada del TUG para predecir caídas en personas mayores que viven en la comunidad, descrita en la revisión sistemática de Barry et al. [13]. En cuanto a la literatura, Altunkaya [12] reportó un 82,2 % de exactitud con las mismas caminatas de LTMM. La diferencia con este trabajo (hasta 0,71) probablemente se debe al esquema de validación y a la forma de seleccionar las variables, por lo que la comparación es solo orientativa. También debe considerarse que la frecuencia dominante se eligió a partir del análisis exploratorio hecho con todas las personas, por lo que su desempeño puede estar algo sobreestimado.

La extensión con registros de vida diaria no mejoró la clasificación, aunque cada persona aportó unos 47 tramos de marcha en lugar de una caminata. Es un resultado negativo, pero informativo. Weiss et al. [1] reportaron que agregar las medidas de vida diaria a las pruebas clínicas mejoraba la identificación de quienes caen, aunque evaluaron ese modelo con las mismas personas con que lo ajustaron; aquí, con validación cruzada por persona, no apareció una ventaja equivalente. Hay tres explicaciones posibles. Primero, la mediana de muchos tramos suaviza justamente la variabilidad, que es lo que podría distinguir a quienes caen. Segundo, la variabilidad medida en la casa casi no se relaciona con la del laboratorio, por lo que ambas fuentes miden aspectos distintos de la marcha. Tercero, más datos por persona no aumentan el número de casos independientes, que sigue siendo de unas 70 personas. Este último punto también explica que la LSTM no mejorara pese a tener cuatro veces más ventanas.

Con un AUC de 0,68 a 0,75, los modelos distinguen a los grupos mejor que el azar, pero no se diferencian claramente del TUG y todavía no alcanzan para usarse como herramienta clínica. Además, como las etiquetas de LTMM son retrospectivas, los modelos reconocen a quienes ya cayeron, pero no predicen caídas futuras. Un resultado favorable para el proyecto es que la variable más informativa, el ritmo de la marcha, en principio se puede medir con una cámara. Todavía no está comprobado: en la sub-etapa 1.2 solo se estimó la cadencia desde las siluetas de CASIA, sin una medida de referencia, y eso muestra coherencia, no exactitud. Esto respalda la idea de llevar el modelo a un prototipo con cámara en la Etapa 2, pero también indica qué hay que validar primero.

V. Limitaciones y próximos pasos

La principal limitación es la cantidad de datos por persona: cada una aporta una sola caminata de laboratorio de alrededor de un minuto, y los registros de vida diaria, aunque aportan mucha más marcha, no aumentan el número de personas. A esto se suman las etiquetas retrospectivas y la gran variación de los resultados entre particiones. Para la sub-etapa 1.4 se proponen los siguientes pasos:

- **Comparación formal.** Comparar los modelos partición por partición, para saber si las diferencias observadas son reales o se deben al azar, y seleccionar el modelo final.
- **Menos variables.** Probar modelos con las variables más importantes, eligiéndolas dentro de la validación cruzada para no repetir el sesgo de elegirlas mirando todos los datos.
- **Vida diaria.** Probar pocas variantes definidas de antemano, como la variabilidad entre tramos de una misma persona o el uso de solo los tramos más largos, para no elegir la variante que mejor resulte por azar. También se considera una limitación que el detector reconoce peor la marcha más irregular y que sus umbrales se calibraron con las caminatas de laboratorio de las mismas personas; como reconoce peor a quienes caen, puede haber un sesgo que el artículo debe declarar.

- **LSTM más simple.** Probar una red más pequeña y más regularizada, aunque con esta cantidad de personas es poco probable que supere a los modelos simples.

Sobre el alcance: la extensión con registros de vida diaria no estaba en el plan original. Se hizo en paralelo, sin retrasar el cronograma (la Etapa 1 se completó antes de lo previsto), y en el artículo se presenta como un análisis secundario con resultado negativo. Además, el plan pedía un notebook con los tres modelos; se entregaron varios (01b, 03 y 04), cuyo orden de ejecución está indicado en el README del repositorio.

VI. Productos

La Tabla VII lista los productos de esta sub-etapa, disponibles en el repositorio del proyecto.

TABLA VII. Productos de la sub-etapa 1.3

Archivo	Contenido
notebooks/01b_Vida_diaria.ipynb	Detector de marcha calibrado, variables por tramo y por persona en los registros de tres días
datos/procesados/vida_diaria_*.csv, combinado_modelo.csv	Variables de vida diaria por persona y tablas de entrada de los modelos
notebooks/03_Modelos_RF_XGBoost.ipynb	Referencias, Random Forest y XGBoost; parámetro DATOS para elegir laboratorio, vida diaria o combinado
notebooks/04_Modelo_LSTM.ipynb	Ventanas de señal, red CNN + LSTM, validación y comparación de los tres modelos
modelos/random_forest*.joblib, xgboost*.joblib	Modelos finales de árboles para cada fuente de datos (checkpoints)
modelos/lstm*.pt	Modelo final de la red para cada fuente de datos (checkpoint)
modelos/info_modelos.json, info_lstm.json	Variables de entrada, parámetros, normalización, métricas y versiones
resultados/*.csv	Métricas por partición y resumen de los tres modelos
figuras/modelos_*.png, lstm_*.png, vida_diaria_*.png	Gráficos de resultados

Referencias

[1] A. Weiss, M. Brozgol, M. Dorfman, T. Herman, S. Shema, N. Giladi, and J. M. Hausdorff, "Does the evaluation of gait quality during daily life provide insight into fall risk? A novel approach using 3-day accelerometer recordings," Neurorehabil. Neural Repair, vol. 27, no. 8, pp. 742–752, 2013, doi: 10.1177/1545968313491004.

[2] J. M. Hausdorff, "Long Term Movement Monitoring Database," version 1.0.0, PhysioNet, 2016, doi: 10.13026/C2S59C.

[3] L. Breiman, "Random forests," Mach. Learn., vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[4] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Comput., vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[6] I. Kiprijanovska, H. Gjoreski, and M. Gams, "Detection of gait abnormalities for fall risk assessment using wrist-worn inertial sensors and deep learning," Sensors, vol. 20, no. 18, Art. no. 5373, Sep. 2020, doi: 10.3390/s20185373.

[7] A. Alqurashi, A. Alharthi, M. M. Alammar, N. Aldosari, and A. Al Ayidh, "Classification of fallers and non-fallers in older adults using electrical IMU signal for gait analysis and explainable deep learning," Sci. Rep., vol. 16, no. 1, Art. no. 14353, Mar. 2026, doi: 10.1038/s41598-026-44368-w.

[8] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," GigaScience, vol. 6, no. 5, Art. no. gix019, May 2017, doi: 10.1093/gigascience/gix019.

[9] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," J. Mach. Learn. Res., vol. 12, pp. 2825–2830, 2011.

[10] A. Paszke et al., "PyTorch: An imperative style, high-performance deep learning library," in Adv. Neural Inf. Process. Syst. 32 (NeurIPS), 2019, pp. 8024–8035.

[11] C. Mou, X. Yan, X. Miao, and L. Zhu, "Accuracy of wearable devices in predicting falls in older adults: A systematic review and meta-analysis," Front. Public Health, vol. 14, Art. no. 1778750, Mar. 2026, doi: 10.3389/fpubh.2026.1778750.

[12] S. Altunkaya, "Leveraging feature selection for enhanced fall risk prediction in elderly using gait analysis," Med. Biol. Eng. Comput., vol. 62, pp. 3887–3897, 2024, doi: 10.1007/s11517-024-03180-2.

[13] E. Barry, R. Galvin, C. Keogh, F. Horgan, and T. Fahey, "Is the Timed Up and Go test a useful predictor of risk of falls in community dwelling older adults: A systematic review and meta-analysis," BMC Geriatr., vol. 14, Art. no. 14, Feb. 2014, doi: 10.1186/1471-2318-14-14.