Clasificación del riesgo de caída en adultos mayores mediante análisis de marcha y aprendizaje automático: avance de la sub-etapa 1.4, evaluación y selección del modelo

Versión 2 (3 de noviembre de 2026). Incorpora las observaciones de la revisión del profesor guía del 1 de noviembre y los análisis complementarios del notebook 05b.

***Resumen*: Este documento presenta el avance de la sub-etapa 1.4 del proyecto, correspondiente a las semanas 10 y 11. Se reunieron los resultados de la sub-etapa 1.3 y se agregaron siete modelos nuevos, con lo que se compararon 27 combinaciones de modelo y fuente de datos: caminatas de laboratorio, registros de tres días de vida diaria y ambas fuentes combinadas. La comparación usó la prueba t corregida para validación cruzada de Nadeau y Bengio, con corrección de Holm. Ningún modelo resultó significativamente peor que el mejor de su fuente, por lo que la selección se basó en criterios escritos antes de ejecutar el análisis: usar solo variables que una cámara pueda medir, no ser peor que el mejor modelo y ser lo más simple posible. El modelo seleccionado para la Etapa 2 es una regresión logística con una sola variable, la frecuencia dominante de la marcha, elegida dentro de cada partición en 46 de 50 casos. Su AUC es de 0,72 (IC 95 %: 0,57 a 0,88). Es numéricamente mayor que el de Random Forest, XGBoost, la LSTM y la prueba clínica TUG, pero sin diferencias significativas; sí supera al azar (p de Holm = 0,017). El umbral de tamizaje equivale a una frecuencia dominante menor que 1,93 Hz, unos 116 pasos por minuto; elegido solo con las personas de entrenamiento, detecta al 78 % de quienes caen con una especificidad de 0,54. La frecuencia dominante se relaciona con la velocidad de marcha (ρ = 0,56), cuyo aporte no se puede separar con esta muestra, y la columna de caídas a 6 meses de la planilla clínica resultó ser retrospectiva. El análisis mostró además que el AUC de 0,75 reportado en la sub-etapa 1.3 para esta variable estaba algo inflado por haberla elegido mirando a todas las personas.**

***Palabras clave*: riesgo de caída, análisis de marcha, selección de modelos, validación cruzada, prueba t corregida, sesgo de selección, tamizaje.**

I. Introducción

La sub-etapa 1.4 tiene como objetivo comparar los modelos entrenados con exactitud, F1-score y AUC mediante validación cruzada, y justificar la selección del mejor modelo para pasar a la Etapa 2. Sus productos son una tabla comparativa de métricas y este informe de selección.

El punto de partida son los resultados de la sub-etapa 1.3. Con las caminatas de laboratorio de la base LTMM [1], [2], Random Forest [3] y XGBoost [4] obtuvieron un AUC de 0,68 y 0,64, y la red CNN + LSTM [5] quedó cerca del azar. La mejor referencia fue una regresión logística con solo la frecuencia dominante (AUC 0,75). La extensión con registros de tres días de vida diaria no mejoró la clasificación. Quedaron tres preguntas abiertas, que esta sub-etapa responde: si las diferencias entre modelos son reales o se deben al azar, si el 0,75 de la frecuencia dominante está inflado, y cuál modelo conviene llevar a un prototipo con cámara.

El documento se organiza así. La Sección II describe la metodología. La Sección III presenta los resultados y la selección del modelo, y la Sección IV los discute. La Sección V resume las limitaciones y los próximos pasos, y la Sección VI, los productos entregados.

Esta segunda versión responde a la revisión del profesor guía. Los cambios principales son: se corrige la frase del resumen que presentaba el modelo elegido como mejor que los demás, se agregan la comparación con el azar y con el TUG, el umbral expresado en Hz, una estimación del umbral sin usar las personas de prueba, la matriz de confusión y la calibración, y se analizan dos columnas de la planilla clínica que el profesor señaló: la velocidad de marcha y las caídas a 6 meses. Esos análisis están en el notebook 05b, cuyo plan se subió al repositorio antes de ejecutarlo.

II. Metodología

A. Resultados comparados

Se reunieron las métricas de cada partición de los notebooks de la sub-etapa 1.3, ejecutados con las tres fuentes de datos: laboratorio (72 personas), vida diaria (70) y combinado (62). Random Forest, XGBoost y las referencias tienen 50 pruebas (validación cruzada estratificada de 5 partes repetida 10 veces), y la LSTM tiene 15, que coinciden con las 15 primeras de los demás. Los modelos nuevos de esta sub-etapa se evaluaron con exactamente las mismas particiones, para poder compararlos de a pares.

B. Comparación estadística

Las pruebas de una validación cruzada no son independientes, porque dos particiones comparten la mayor parte de sus personas de entrenamiento. Una prueba t común subestima la varianza y encuentra diferencias significativas que no lo son. Por eso se usó la prueba t pareada corregida de Nadeau y Bengio [6], que multiplica la varianza de las diferencias por (1/J + n_prueba/n_entrenamiento), donde J es el número de pruebas; Bouckaert y Frank [7] mostraron que esta corrección da resultados más confiables y repetibles. Con la misma corrección se calculó un intervalo de confianza del 95 % para el AUC de cada modelo.

Dentro de cada fuente de datos, cada modelo se comparó con el de mayor AUC promedio, y los valores p se ajustaron con el método de Holm [8]. La referencia de una variable elegida en el análisis exploratorio se dejó fuera como punto de comparación, porque su AUC puede estar inflado. Los modelos de fuentes distintas no se compararon de a pares, porque no tienen exactamente las mismas personas; para ellos se comparan los intervalos de confianza.

C. Análisis adicionales

Con pocas personas, probar muchas variantes y reportar la mejor produce resultados optimistas por puro azar. Por eso los análisis nuevos se escribieron al inicio del notebook 05 antes de ejecutarlo. Hay que decir, eso sí, que ese notebook se subió al repositorio junto con sus resultados, así que el historial no permite comprobarlo de forma independiente. Para corregirlo, desde la revisión el plan de cada análisis nuevo se sube antes de ejecutarlo, como se hizo con el notebook 05b. Los análisis fueron:

- **Selección de variables dentro de cada partición.** En la sub-etapa 1.3, la frecuencia dominante se eligió mirando a todas las personas. Es un sesgo conocido: si las variables se eligen fuera de la validación cruzada, el desempeño estimado sale demasiado optimista [9]. Para medirlo, se evaluaron regresiones logísticas que eligen 1 o 3 variables (prueba F) usando solo las personas de entrenamiento de cada partición.

- **Variables medibles con cámara.** Se definieron nueve variables de ritmo y de tiempo de la marcha que pueden obtenerse de un video: cadencia, tiempo de paso y de zancada, sus coeficientes de variación, regularidad de paso y de zancada, simetría y frecuencia dominante. Las aceleraciones y los giros quedaron fuera, porque dependen del sensor. Con ellas se evaluaron una regresión logística con una variable elegida en cada partición, una regresión logística con las nueve y un Random Forest con las nueve. Esta lista se armó cuando ya se sabía, por el análisis exploratorio, que la frecuencia dominante era la variable más prometedora, de modo que pudo estar influida por los datos.
- **Variantes de vida diaria.** Mediana de las variables usando solo tramos de al menos 60 s, y variabilidad de cada variable entre los tramos de una misma persona (rango intercuartílico relativo), cada una con regresión logística y con Random Forest.

D. Criterios de selección

El modelo final se eligió con tres criterios, en este orden:

- **Uso en la Etapa 2.** En el prototipo, la persona camina unos metros frente a una cámara. Esa situación se parece a la caminata de laboratorio, no a tres días con un sensor, y la cámara puede medir el ritmo y los tiempos de la marcha, pero no las aceleraciones. Saeb et al. [10] recomiendan evaluar un modelo en condiciones parecidas a las de su uso real. Por eso los candidatos fueron los tres modelos de laboratorio con variables medibles con cámara.
- **Desempeño.** No ser significativamente peor que el mejor modelo de laboratorio (p de Holm ≥ 0,05).
- **Simplicidad.** Entre los que cumplen los dos criterios anteriores, el de menos variables. Un modelo simple se sobreajusta menos, se explica mejor a un profesional clínico y funciona sin problemas en una Raspberry Pi.

E. Punto de operación

Un umbral de 0,5 no es necesariamente el adecuado. En un tamizaje importa más detectar a quien cae que evitar falsas alarmas. Por eso se buscó el umbral que logra una sensibilidad de al menos 80 %, usando predicciones de validación cruzada, en las que cada persona es clasificada por un modelo que no la vio. El proceso se repitió 10 veces y se informa la especificidad obtenida con ese umbral.

Como ese umbral se calcula con las mismas 72 personas, su especificidad es optimista. En la versión 2 se estimó también de forma honesta: en cada partición, el umbral se eligió solo con las personas de entrenamiento (mediante una validación interna de 5 partes) y se aplicó a las de prueba. Además, se informa la matriz de confusión con ese umbral, el puntaje de Brier, que mide qué tan cerca están las probabilidades predichas de lo que realmente ocurre, y una curva de calibración.

F. Análisis complementarios pedidos en la revisión

- **Velocidad de marcha.** La planilla clínica de LTMM incluye la velocidad de marcha de 68 personas. Con ella se evaluó la referencia «solo velocidad» que el avance 1.1 había propuesto, y que se había reemplazado por la frecuencia dominante porque el sensor lumbar no permite medir la velocidad. También se evaluó la velocidad junto con la frecuencia dominante, en las mismas 50 particiones.

- **Mismas personas.** En la sub-etapa 1.3, a 4 personas sin TUG se les asignó la mediana de entrenamiento. Para una comparación más limpia, la frecuencia dominante, la velocidad y el TUG se evaluaron también solo con las 68 personas que tienen los tres datos.
- **Comparación con el azar y con el TUG.** La Sección III-B compara cada modelo con el mejor. La pregunta clínica, en cambio, es si el modelo elegido supera al azar (AUC = 0,5) y a la prueba que hoy se usa, el TUG. Se usó la misma prueba t corregida, con Holm sobre las cuatro comparaciones.
- **Caídas a 6 meses.** La planilla tiene una columna «6 Months Fall» con datos de 66 personas. Weiss et al. [1] registraron dos cosas distintas: las caídas de los 6 meses anteriores al estudio y un seguimiento posterior de 6 meses. Antes de usarla como etiqueta de caídas futuras, se revisó a cuál de las dos corresponde.

III. Resultados

A. Tabla comparativa de métricas

La Tabla I muestra las métricas de todos los modelos con las caminatas de laboratorio, y la Tabla II, los principales resultados con vida diaria y con ambas fuentes combinadas. La Fig. 1 muestra el intervalo de confianza del AUC de los 24 modelos, sin contar la referencia sin modelo.

TABLA I. Métricas con las caminatas de laboratorio (72 personas)

Modelo	Exactitud	Sensibilidad	Especificidad	F1	AUC
Solo frecuencia dominante (elegida en el EDA)	0,70 ± 0,12	0,60 ± 0,19	0,80 ± 0,13	0,65 ± 0,15	0,75 ± 0,13
1 variable de cámara elegida en cada partición	**0,69 ± 0,12**	**0,57 ± 0,21**	**0,80 ± 0,13**	**0,62 ± 0,17**	**0,72 ± 0,15**
Random Forest	0,61 ± 0,11	0,60 ± 0,17	0,61 ± 0,18	0,59 ± 0,12	0,68 ± 0,14
Random Forest, variables de cámara	0,63 ± 0,10	0,60 ± 0,17	0,66 ± 0,17	0,60 ± 0,12	0,66 ± 0,14
Solo TUG	0,56 ± 0,13	0,40 ± 0,19	0,71 ± 0,20	0,45 ± 0,16	0,66 ± 0,14
3 variables elegidas en cada partición	0,61 ± 0,13	0,58 ± 0,17	0,63 ± 0,17	0,58 ± 0,15	0,65 ± 0,15
XGBoost	0,59 ± 0,13	0,55 ± 0,19	0,64 ± 0,19	0,55 ± 0,15	0,64 ± 0,15
Logística, variables de cámara	0,63 ± 0,11	0,54 ± 0,18	0,71 ± 0,14	0,57 ± 0,16	0,63 ± 0,15
1 variable elegida en cada partición	0,60 ± 0,15	0,52 ± 0,18	0,67 ± 0,18	0,55 ± 0,17	0,62 ± 0,17
LSTM (15 pruebas)	0,53 ± 0,07	0,58 ± 0,36	0,48 ± 0,38	0,47 ± 0,24	0,55 ± 0,15
Sin modelo	0,53 ± 0,03	0,00 ± 0,00	1,00 ± 0,00	0,00 ± 0,00	0,50 ± 0,00

Los valores son media ± desviación estándar de 50 pruebas (15 en la LSTM). En negrita, el modelo seleccionado.

TABLA II. Resultados con vida diaria y con ambas fuentes combinadas

Modelo	Sensibilidad	Especificidad	AUC	IC 95 % del AUC
Vida diaria (70 personas)				
Variabilidad entre tramos, Random Forest	0,51 ± 0,19	0,70 ± 0,16	0,64 ± 0,13	0,51 a 0,77
LSTM (15 pruebas)	0,21 ± 0,21	0,91 ± 0,10	0,62 ± 0,17	0,42 a 0,83
Random Forest	0,50 ± 0,21	0,71 ± 0,16	0,62 ± 0,16	0,45 a 0,79
XGBoost	0,49 ± 0,21	0,71 ± 0,14	0,61 ± 0,16	0,44 a 0,77
Tramos largos, 3 variables elegidas	0,34 ± 0,17	0,84 ± 0,17	0,59 ± 0,17	0,41 a 0,77
Combinado (62 personas)				
Solo frecuencia dominante (EDA)	0,50 ± 0,18	0,82 ± 0,14	0,70 ± 0,13	0,56 a 0,84
Solo TUG	0,31 ± 0,17	0,90 ± 0,16	0,63 ± 0,17	0,45 a 0,80
Random Forest	0,52 ± 0,19	0,69 ± 0,15	0,62 ± 0,15	0,47 a 0,77
XGBoost	0,39 ± 0,17	0,69 ± 0,17	0,55 ± 0,14	0,40 a 0,70

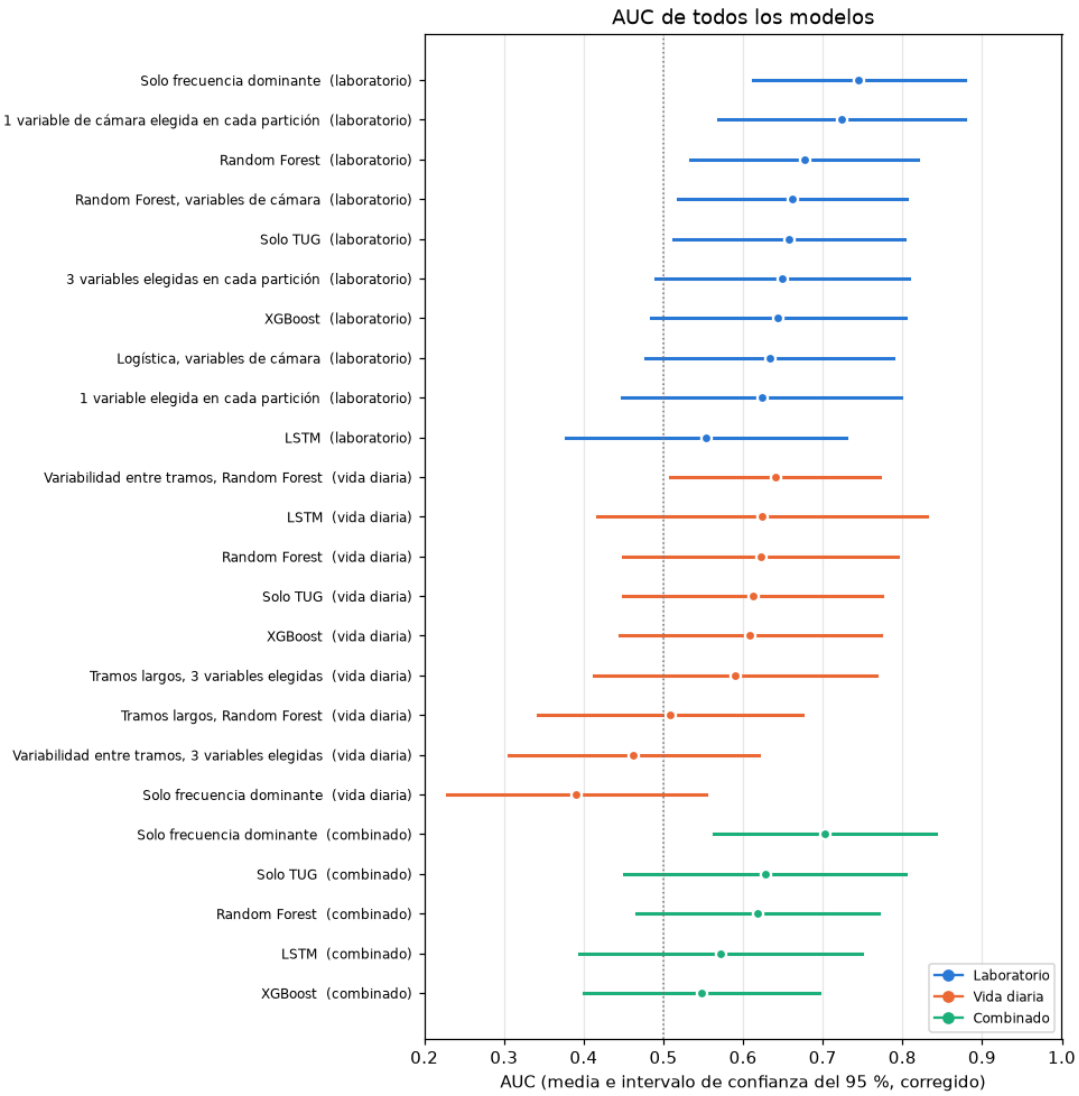


Fig. 1. AUC promedio e intervalo de confianza del 95 % (con varianza corregida) de todos los modelos, según la fuente de datos. La línea punteada marca el nivel del azar (0,5).

B. Comparación estadística

Ningún modelo fue significativamente peor que el mejor de su fuente de datos después de la corrección de Holm. Con laboratorio, el mejor fue la regresión logística con una variable de cámara elegida en cada partición (AUC 0,72), y sus diferencias con Random Forest (0,05), XGBoost (0,08) y la LSTM (0,20) no fueron significativas (p sin corregir de 0,51, 0,35 y 0,08). Es decir, su AUC es numéricamente mayor, pero los datos no permiten afirmar que sea mejor. Los intervalos de confianza son anchos, de unos ±0,15, y se superponen casi por completo (Fig. 1). Con unas 70 personas, la validación no alcanza para distinguir modelos cuyo AUC difiere en menos de unos 0,15.

C. Sesgo de selección de la variable

Cuando se dejó que el modelo eligiera una variable entre las 14 dentro de cada partición, el AUC bajó de 0,75 a 0,62. La frecuencia dominante fue elegida solo en 28 de las 50 particiones; en las demás, el

procedimiento eligió variables como el RMS de la aceleración anteroposterior, que en esa muestra de entrenamiento parecían mejores (Fig. 2). En cambio, al elegir solo entre las variables medibles con cámara, la frecuencia dominante fue elegida en 46 de 50 particiones y el AUC fue de 0,72. Es decir, la ventaja de la frecuencia dominante es real, pero el 0,75 de la sub-etapa 1.3 estaba algo inflado, y la estimación honesta se encuentra entre 0,62 y 0,72 según cuántas variables compitan.

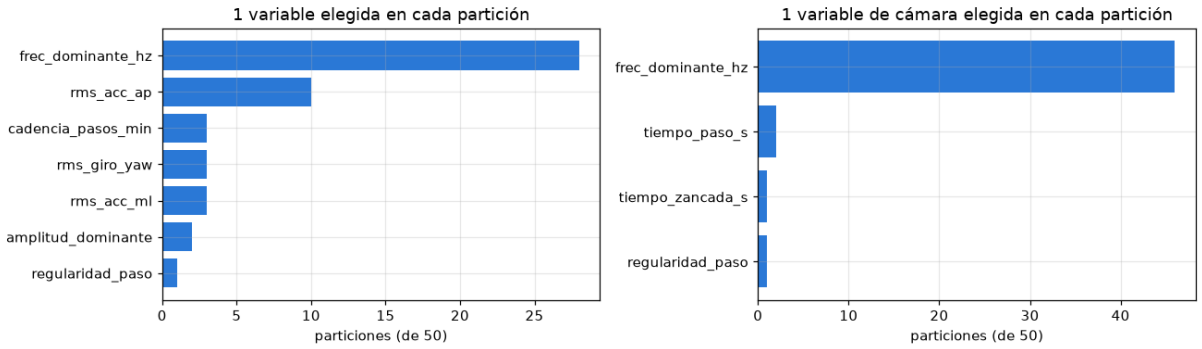


Fig. 2. Variable elegida en cada una de las 50 particiones por la regresión logística de una variable: entre todas las variables (izquierda) y solo entre las medibles con cámara (derecha).

D. Variantes de vida diaria

Ninguna variante de vida diaria mejoró la clasificación. La mejor, la variabilidad entre tramos con Random Forest, obtuvo un AUC de 0,64, apenas sobre el 0,62 del Random Forest original y sin diferencia significativa. Usar solo tramos largos no ayudó (0,51 a 0,59). Se mantiene, por lo tanto, el resultado negativo de la extensión con vida diaria.

E. Modelo seleccionado

La Tabla III resume la aplicación de los criterios. Los tres candidatos cumplieron el criterio de desempeño, y el más simple fue además el de mayor AUC. El modelo seleccionado es una regresión logística con la frecuencia dominante de la marcha, entrenada con las 72 personas. Conviene distinguir dos números. El AUC de 0,72 corresponde al procedimiento completo, que elige la variable dentro de cada partición, y es la estimación que se informa como desempeño esperado. El modelo guardado, en cambio, usa siempre la frecuencia dominante, porque fue la variable que ese procedimiento eligió en 46 de 50 particiones; si se evalúa con la variable fija, su AUC es 0,75, pero ese valor está inflado por el sesgo de selección. Su coeficiente estandarizado es de −0,87: cada desviación estándar de menor frecuencia aumenta el riesgo estimado, lo que concuerda con el análisis exploratorio, en el que quienes caen mostraron una frecuencia dominante menor (1,78 frente a 1,93 Hz).

TABLA III. Aplicación de los criterios de selección a los candidatos

Candidato (laboratorio, variables de cámara)	Variables	AUC	p Holm frente al mejor	Seleccionado
Regresión logística, 1 variable elegida en cada partición	**1**	**0,72**	**—**	**Sí**
Random Forest	9	0,66	1,00	No (más complejo)
Regresión logística	9	0,63	1,00	No (más complejo)

Con el umbral de 0,5, el modelo tiene una sensibilidad de 0,57 y una especificidad de 0,80. Para tamizaje se buscó el umbral que detecta al menos al 80 % de quienes caen: es de 0,40 (mediana de 10 repeticiones), y con él la especificidad baja a 0,47 ± 0,05 (Fig. 3). En otras palabras, para no dejar pasar a 8 de cada 10 personas que caen, el modelo daría una falsa alarma a aproximadamente la mitad de quienes no caen. El modelo, su umbral y los criterios de selección quedaron guardados para la Etapa 2.

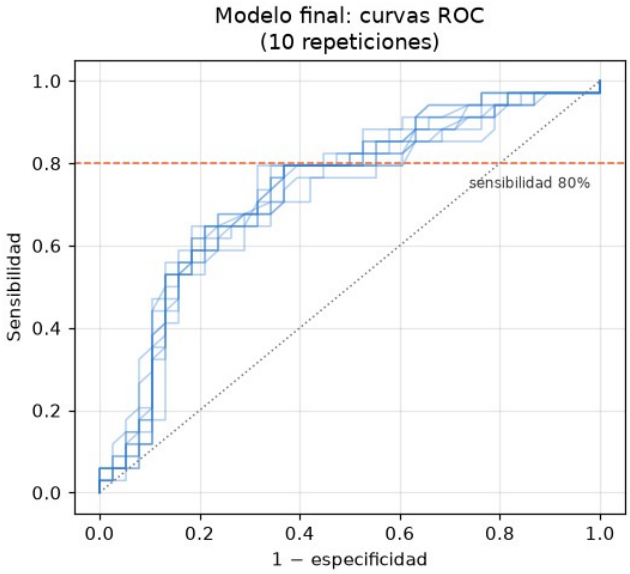


Fig. 3. Curvas ROC del modelo seleccionado en 10 repeticiones de la validación cruzada. La línea discontinua marca la sensibilidad objetivo de 80 %.

Como el modelo tiene una sola variable, el umbral de probabilidad de 0,40 equivale a un valor de frecuencia dominante: se marca riesgo cuando es menor que 1,93 Hz, unos 116 pasos por minuto. Es un número más fácil de explicar a un kinesiólogo y de trasladar a la cámara. Como referencia, la frecuencia dominante media fue de 1,93 Hz en quienes no caen y de 1,81 Hz en quienes caen.

Con el umbral elegido solo con las personas de entrenamiento, la sensibilidad fue de 0,78 ± 0,04 y la especificidad de 0,54 ± 0,04 (Fig. 4). En promedio, de las 34 personas que caen, el modelo detecta a 26,6, y

de las 38 que no caen, marca como riesgo a 17,5. El puntaje de Brier fue de 0,216, frente a 0,249 de un modelo que siempre predice la proporción de personas que caen; la mejora es modesta, y la curva de calibración muestra que las probabilidades predichas siguen razonablemente a las observadas.

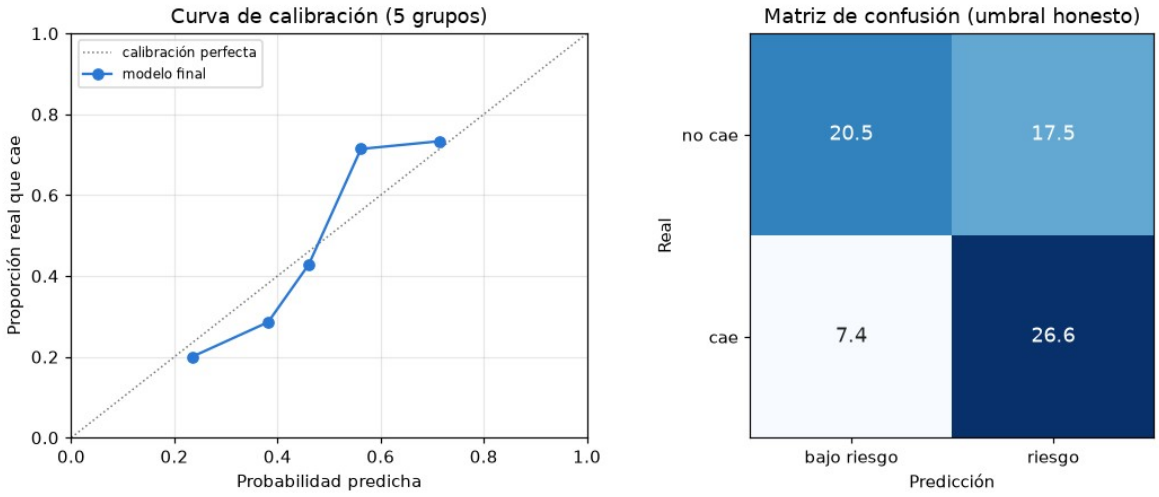


Fig. 4. Curva de calibración del modelo seleccionado con predicciones de validación cruzada (izquierda) y matriz de confusión con el umbral elegido solo con las personas de entrenamiento, promedio de 10 repeticiones (derecha).

F. Análisis complementarios

La Tabla IV resume la comparación con la velocidad de marcha y con el TUG. El modelo elegido supera al azar (p de Holm = 0,017), pero su diferencia con el TUG (0,07) no es significativa (p de Holm = 0,47). En las mismas 68 personas, la frecuencia dominante, la velocidad y el TUG superan al azar y no se distinguen entre sí.

TABLA IV. Frecuencia dominante, velocidad y TUG

Modelo	AUC	IC 95 %	p de Holm frente al azar
Todas las personas (72), mismas 50 particiones			
1 variable de cámara elegida en cada partición	0,72	0,57 a 0,88	0,017
Velocidad + frecuencia dominante	0,72	0,58 a 0,86	—
Solo velocidad	0,67	0,50 a 0,83	—
Solo TUG	0,66	0,51 a 0,80	—
Mismas 68 personas, sin completar datos			
Solo frecuencia dominante	0,74	0,60 a 0,88	0,005
Solo velocidad	0,69	0,55 a 0,83	0,010
Solo TUG	0,68	0,56 a 0,79	0,007

El IC del TUG con todas las personas viene de la tabla comparativa del notebook 05; «—» indica que esa comparación no se hizo.

La frecuencia dominante y la velocidad están correlacionadas (ρ de Spearman = 0,56; Fig. 5). Agregar la frecuencia dominante a la velocidad sube el AUC de 0,67 a 0,72, pero la diferencia no es significativa (p = 0,29). Con 72 personas no se puede separar cuánto aporta cada una.

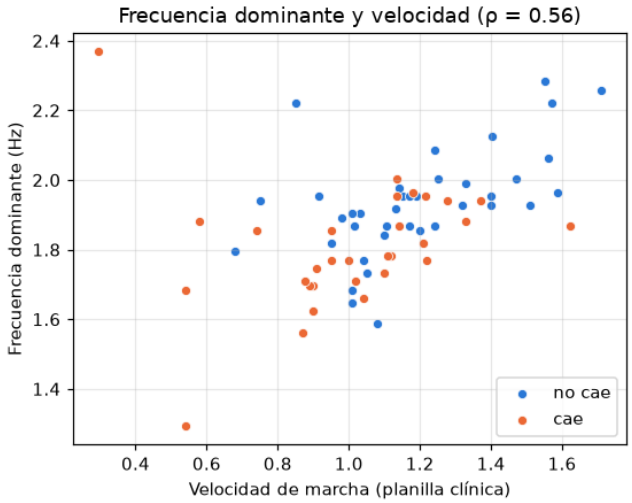


Fig. 5. Frecuencia dominante frente a velocidad de marcha de la planilla clínica, según grupo.

La columna de caídas a 6 meses resultó ser retrospectiva, es decir, cuenta las caídas de los 6 meses anteriores al estudio. Su correlación con las caídas del año anterior es de ρ = 0,93, y estas la predicen con un AUC de 0,98, algo imposible para caídas futuras. Sus medias (2,86 en quienes caen y 0,14 en quienes no) coinciden con la variable «caídas en los últimos 6 meses» de la Tabla 1 de Weiss et al. [1] (2,56 y 0,15), y 22 personas tienen 2 o más caídas, frente a 12 en el seguimiento posterior. La regla escrita en el plan del notebook 05b concluyó «posiblemente prospectiva» porque sus umbrales eran demasiado estrictos (exigía al menos 90 % de personas que caen entre quienes tenían caídas en la columna y como máximo 2 controles con caídas; hubo 84 % y 5). Se deja registrado ese error y la columna no se usa como etiqueta nueva.

IV. Discusión

El resultado principal es que, con estos datos, no hay un modelo claramente superior. Las diferencias entre Random Forest, XGBoost, la LSTM, el TUG y los modelos de una variable están dentro de lo que se puede explicar por azar. Esto confirma la advertencia de Mou et al. [11] sobre los estudios con menos de 100 participantes, y justifica haber definido criterios de selección de antemano: cuando el desempeño no decide, deciden el uso real y la simplicidad. El plan del proyecto anticipa este escenario al señalar que un benchmark honesto es un resultado válido.

El modelo seleccionado es el más simple posible, y aun así no fue superado por ninguno de los modelos de aprendizaje automático. La frecuencia dominante mide el ritmo de la marcha a partir del espectro de la aceleración vertical; que funcione mejor que la cadencia, que mide lo mismo contando pasos, sugiere que la estimación espectral es más estable que la detección de pasos individuales en caminatas cortas. Esto es favorable para la Etapa 2: la frecuencia del movimiento vertical también puede estimarse con una cámara, por ejemplo siguiendo la altura de la cadera con MediaPipe. Eso todavía está por comprobarse: en la sub-etapa 1.2 solo se estimó la cadencia desde el ancho de las siluetas de CASIA, sin una medida de referencia, lo que muestra que la estimación es coherente, pero no que sea exacta.

La relación con la velocidad obliga a matizar la interpretación. Las personas que caminan más lento suelen dar pasos a un ritmo menor, así que la frecuencia dominante podría ser en parte un reflejo de la velocidad. Para el proyecto no es un problema, porque ambas se pueden estimar con una cámara, pero el artículo no debe presentar la frecuencia dominante como un marcador independiente de la velocidad.

El análisis del sesgo de selección es una contribución metodológica útil para el artículo. Elegir la variable mirando a todas las personas, como se hizo en el análisis exploratorio, infló el AUC en hasta 0,13 [9]. Este efecto es frecuente en la literatura de riesgo de caída y puede explicar parte de las diferencias con trabajos que reportan exactitudes mayores con la misma base, como el 82,2 % de Altunkaya [12].

Desde el punto de vista clínico, el modelo todavía es limitado: con una sensibilidad cercana a 80 %, la especificidad honesta es de 0,54, y su desempeño no se distingue del TUG. Sería útil como un primer filtro que indique a quién conviene hacerle una evaluación completa, no como diagnóstico. Su ventaja práctica frente al TUG no es el desempeño, sino que podría medirse con una cámara sin que un profesional cronometre la prueba. Además, como las etiquetas de LTMM son retrospectivas, y la columna de 6 meses también lo es, el modelo reconoce a quienes ya cayeron y no predice caídas futuras.

V. Limitaciones y próximos pasos

Las principales limitaciones son el tamaño de la muestra, que deja intervalos de confianza de unos ±0,15 en el AUC; las etiquetas retrospectivas; y que la frecuencia dominante se midió con un acelerómetro en la espalda baja, mientras que en la Etapa 2 se medirá con una cámara. El conjunto de variables medibles con cámara se definió por criterio, después del análisis exploratorio, y debe confirmarse en la práctica. A esto se suman otros posibles sesgos que el artículo debe declarar: el filtro de variables redundantes (correlación de Spearman mayor que 0,9) se aplicó a las 72 personas antes de la validación cruzada, aunque sin usar la etiqueta; quienes caen tienen caminatas 9,4 s más largas, lo que puede afectar a las variables que se estiman con más pasos; y el umbral del notebook 05 se eligió sin un conjunto independiente. Los próximos pasos son:

- **Artículo (sub-etapa 1.5).** Redactar el artículo metodológico en plantilla IEEE, con el benchmark honesto, el análisis del sesgo de selección y el resultado negativo de la vida diaria como aportes principales.
- **Etapa 2.** Como el modelo es una sola fórmula, lo difícil ya no es llevarlo a la Raspberry Pi, sino medir bien la frecuencia dominante con la cámara. Por eso conviene replantear las sub-etapas 2.1 y 2.2 con ese foco: validar la frecuencia medida con cámara frente a un sensor inercial en las mismas personas. Para probar MediaPipe se necesita video RGB, porque las siluetas de CASIA descargadas no sirven. El umbral de 1,93 Hz deberá recalibrarse con las mediciones de cámara y validarse en la prueba piloto de la sub-etapa 2.4.

VI. Productos

La Tabla V lista los productos de esta sub-etapa, disponibles en el repositorio del proyecto.

TABLA V. Productos de la sub-etapa 1.4

Archivo	Contenido
notebooks/ 05_Evaluacion_y_seleccion.ipynb	Comparación estadística, análisis definidos de antemano y selección del modelo final
resultados/tabla_comparativa.csv	Tabla comparativa de métricas de los 27 modelos y fuentes de datos
resultados/comparacion_estadistica.csv	Prueba t corregida y Holm de cada modelo frente al mejor de su fuente
resultados/metricas_por_particion_1_4.csv	Métricas por partición de los modelos nuevos
modelos/modelo_final.joblib, info_modelo_final.json	Modelo seleccionado, su umbral de tamizaje y la justificación
figuras/seleccion_*.png	Gráficos de esta sub-etapa
notebooks/05b_Respuesta_revision.ipynb	Análisis complementarios de la revisión (versión 2)
requirements.txt	Versiones exactas de las librerías usadas
resultados/revision_*.csv, figuras/revision_*.png	Resultados y gráficos del notebook 05b

Referencias

[1] A. Weiss, M. Brozgol, M. Dorfman, T. Herman, S. Shema, N. Giladi, and J. M. Hausdorff, "Does the evaluation of gait quality during daily life provide insight into fall risk? A novel approach using 3-day accelerometer recordings," Neurorehabil. Neural Repair, vol. 27, no. 8, pp. 742–752, 2013, doi: 10.1177/1545968313491004.

[2] J. M. Hausdorff, "Long Term Movement Monitoring Database," version 1.0.0, PhysioNet, 2016, doi: 10.13026/C2S59C.

[3] L. Breiman, "Random forests," Mach. Learn., vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[4] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Comput., vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[6] C. Nadeau and Y. Bengio, "Inference for the generalization error," Mach. Learn., vol. 52, no. 3, pp. 239–281, 2003, doi: 10.1023/A:1024068626366.

[7] R. R. Bouckaert and E. Frank, "Evaluating the replicability of significance tests for comparing learning algorithms," in Advances in Knowledge Discovery and Data Mining (PAKDD 2004), Lecture Notes in Computer Science, vol. 3056. Berlin, Germany: Springer, 2004, pp. 3–12.

[8] S. Holm, "A simple sequentially rejective multiple test procedure," Scand. J. Statist., vol. 6, no. 2, pp. 65–70, 1979.

[9] C. Ambroise and G. J. McLachlan, "Selection bias in gene extraction on the basis of microarray gene-expression data," Proc. Natl. Acad. Sci. USA, vol. 99, no. 10, pp. 6562–6566, 2002, doi: 10.1073/pnas.102102699.

[10] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," GigaScience, vol. 6, no. 5, Art. no. gix019, May 2017, doi: 10.1093/gigascience/gix019.

[11] C. Mou, X. Yan, X. Miao, and L. Zhu, "Accuracy of wearable devices in predicting falls in older adults: A systematic review and meta-analysis," Front. Public Health, vol. 14, Art. no. 1778750, Mar. 2026, doi: 10.3389/fpubh.2026.1778750.

[12] S. Altunkaya, "Leveraging feature selection for enhanced fall risk prediction in elderly using gait analysis," Med. Biol. Eng. Comput., vol. 62, pp. 3887–3897, 2024, doi: 10.1007/s11517-024-03180-2.