Clasificación del riesgo de caída en adultos mayores mediante análisis de marcha y aprendizaje automático: avance de la sub-etapa 1.4, evaluación y selección del modelo

***Resumen*: Este documento presenta el avance de la sub-etapa 1.4 del proyecto, correspondiente a las semanas 10 y 11. Se reunieron los resultados de la sub-etapa 1.3 y se agregaron siete modelos definidos antes de ver los resultados, con lo que se compararon 27 combinaciones de modelo y fuente de datos: caminatas de laboratorio, registros de tres días de vida diaria y ambas fuentes combinadas. La comparación usó la prueba t corregida para validación cruzada de Nadeau y Bengio, con corrección de Holm. Ningún modelo resultó significativamente peor que el mejor de su fuente, por lo que la selección se basó en criterios fijados de antemano: usar solo variables que una cámara pueda medir, no ser peor que el mejor modelo y ser lo más simple posible. El modelo seleccionado para la Etapa 2 es una regresión logística con una sola variable, la frecuencia dominante de la marcha, elegida dentro de cada partición en 46 de 50 casos. Su AUC es de 0,72 (IC 95 %: 0,57 a 0,88), mayor que el de Random Forest, XGBoost, la LSTM y la prueba clínica TUG. Con un umbral que detecta al 80 % de quienes caen, su especificidad es de 0,47. El análisis mostró además que el AUC de 0,75 reportado en la sub-etapa 1.3 para esta variable estaba algo inflado por haberla elegido mirando a todas las personas.**

***Palabras clave*: riesgo de caída, análisis de marcha, selección de modelos, validación cruzada, prueba t corregida, sesgo de selección, tamizaje.**

I. Introducción

La sub-etapa 1.4 tiene como objetivo comparar los modelos entrenados con exactitud, F1-score y AUC mediante validación cruzada, y justificar la selección del mejor modelo para pasar a la Etapa 2. Sus productos son una tabla comparativa de métricas y este informe de selección.

El punto de partida son los resultados de la sub-etapa 1.3. Con las caminatas de laboratorio de la base LTMM [1], [2], Random Forest [3] y XGBoost [4] obtuvieron un AUC de 0,68 y 0,64, y la red CNN + LSTM [5] quedó cerca del azar. La mejor referencia fue una regresión logística con solo la frecuencia dominante (AUC 0,75). La extensión con registros de tres días de vida diaria no mejoró la clasificación. Quedaron tres preguntas abiertas, que esta sub-etapa responde: si las diferencias entre modelos son reales o se deben al azar, si el 0,75 de la frecuencia dominante está inflado, y cuál modelo conviene llevar a un prototipo con cámara.

El documento se organiza así. La Sección II describe la metodología. La Sección III presenta los resultados y la selección del modelo, y la Sección IV los discute. La Sección V resume las limitaciones y los próximos pasos, y la Sección VI, los productos entregados.

II. Metodología

A. Resultados comparados

Se reunieron las métricas de cada partición de los notebooks de la sub-etapa 1.3, ejecutados con las tres fuentes de datos: laboratorio (72 personas), vida diaria (70) y combinado (62). Random Forest, XGBoost y

las referencias tienen 50 pruebas (validación cruzada estratificada de 5 partes repetida 10 veces), y la LSTM tiene 15, que coinciden con las 15 primeras de los demás. Los modelos nuevos de esta sub-etapa se evaluaron con exactamente las mismas particiones, para poder compararlos de a pares.

B. Comparación estadística

Las pruebas de una validación cruzada no son independientes, porque dos particiones comparten la mayor parte de sus personas de entrenamiento. Una prueba t común subestima la varianza y encuentra diferencias significativas que no lo son. Por eso se usó la prueba t pareada corregida de Nadeau y Bengio [6], que multiplica la varianza de las diferencias por (1/J + n_prueba/n_entrenamiento), donde J es el número de pruebas; Bouckaert y Frank [7] mostraron que esta corrección da resultados más confiables y repetibles. Con la misma corrección se calculó un intervalo de confianza del 95 % para el AUC de cada modelo.

Dentro de cada fuente de datos, cada modelo se comparó con el de mayor AUC promedio, y los valores p se ajustaron con el método de Holm [8]. La referencia de una variable elegida en el análisis exploratorio se dejó fuera como punto de comparación, porque su AUC puede estar inflado. Los modelos de fuentes distintas no se compararon de a pares, porque no tienen exactamente las mismas personas; para ellos se comparan los intervalos de confianza.

C. Análisis definidos de antemano

Con pocas personas, probar muchas variantes y reportar la mejor produce resultados optimistas por puro azar. Por eso todos los análisis nuevos se fijaron antes de ver sus resultados:

- **Selección de variables dentro de cada partición.** En la sub-etapa 1.3, la frecuencia dominante se eligió mirando a todas las personas. Es un sesgo conocido: si las variables se eligen fuera de la validación cruzada, el desempeño estimado sale demasiado optimista [9]. Para medirlo, se evaluaron regresiones logísticas que eligen 1 o 3 variables (prueba F) usando solo las personas de entrenamiento de cada partición.
- **Variables medibles con cámara.** Se definieron nueve variables de ritmo y de tiempo de la marcha que pueden obtenerse de un video: cadencia, tiempo de paso y de zancada, sus coeficientes de variación, regularidad de paso y de zancada, simetría y frecuencia dominante. Las aceleraciones y los giros quedaron fuera, porque dependen del sensor. Con ellas se evaluaron una regresión logística con una variable elegida en cada partición, una regresión logística con las nueve y un Random Forest con las nueve.
- **Variantes de vida diaria.** Mediana de las variables usando solo tramos de al menos 60 s, y variabilidad de cada variable entre los tramos de una misma persona (rango intercuartílico relativo), cada una con regresión logística y con Random Forest.

D. Criterios de selección

El modelo final se eligió con tres criterios, en este orden:

- **Uso en la Etapa 2.** En el prototipo, la persona camina unos metros frente a una cámara. Esa situación se parece a la caminata de laboratorio, no a tres días con un sensor, y la cámara puede medir el ritmo y los tiempos de la marcha, pero no las aceleraciones. Saeb et al. [10] recomiendan

evaluar un modelo en condiciones parecidas a las de su uso real. Por eso los candidatos fueron los tres modelos de laboratorio con variables medibles con cámara.

- **Desempeño.** No ser significativamente peor que el mejor modelo de laboratorio (p de Holm ≥ 0,05).
- **Simplicidad.** Entre los que cumplen los dos criterios anteriores, el de menos variables. Un modelo simple se sobreajusta menos, se explica mejor a un profesional clínico y funciona sin problemas en una Raspberry Pi.

E. Punto de operación

Un umbral de 0,5 no es necesariamente el adecuado. En un tamizaje importa más detectar a quien cae que evitar falsas alarmas. Por eso se buscó el umbral que logra una sensibilidad de al menos 80 %, usando predicciones de validación cruzada, en las que cada persona es clasificada por un modelo que no la vio. El proceso se repitió 10 veces y se informa la especificidad obtenida con ese umbral.

III. Resultados

A. Tabla comparativa de métricas

La Tabla I muestra las métricas de todos los modelos con las caminatas de laboratorio, y la Tabla II, los principales resultados con vida diaria y con ambas fuentes combinadas. La Fig. 1 muestra el intervalo de confianza del AUC de los 24 modelos, sin contar la referencia sin modelo.

TABLA I. Métricas con las caminatas de laboratorio (72 personas)

Modelo	Exactitud	Sensibilidad	Especificidad	F1	AUC
Solo frecuencia dominante (elegida en el EDA)	0,70 ± 0,12	0,60 ± 0,19	0,80 ± 0,13	0,65 ± 0,15	0,75 ± 0,13
1 variable de cámara elegida en cada partición	**0,69 ± 0,12**	**0,57 ± 0,21**	**0,80 ± 0,13**	**0,62 ± 0,17**	**0,72 ± 0,15**
Random Forest	0,61 ± 0,11	0,60 ± 0,17	0,61 ± 0,18	0,59 ± 0,12	0,68 ± 0,14
Random Forest, variables de cámara	0,63 ± 0,10	0,60 ± 0,17	0,66 ± 0,17	0,60 ± 0,12	0,66 ± 0,14
Solo TUG	0,56 ± 0,13	0,40 ± 0,19	0,71 ± 0,20	0,45 ± 0,16	0,66 ± 0,14
3 variables elegidas en cada partición	0,61 ± 0,13	0,58 ± 0,17	0,63 ± 0,17	0,58 ± 0,15	0,65 ± 0,15
XGBoost	0,59 ± 0,13	0,55 ± 0,19	0,64 ± 0,19	0,55 ± 0,15	0,64 ± 0,15
Logística, variables de cámara	0,63 ± 0,11	0,54 ± 0,18	0,71 ± 0,14	0,57 ± 0,16	0,63 ± 0,15
1 variable elegida en cada partición	0,60 ± 0,15	0,52 ± 0,18	0,67 ± 0,18	0,55 ± 0,17	0,62 ± 0,17
LSTM (15 pruebas)	0,53 ± 0,07	0,58 ± 0,36	0,48 ± 0,38	0,47 ± 0,24	0,55 ± 0,15
Sin modelo	0,53 ± 0,03	0,00 ± 0,00	1,00 ± 0,00	0,00 ± 0,00	0,50 ± 0,00

Los valores son media ± desviación estándar de 50 pruebas (15 en la LSTM). En negrita, el modelo seleccionado.

TABLA II. Resultados con vida diaria y con ambas fuentes combinadas

Modelo	Sensibilidad	Especificidad	AUC	IC 95 % del AUC
Vida diaria (70 personas)				
Variabilidad entre tramos, Random Forest	0,51 ± 0,19	0,70 ± 0,16	0,64 ± 0,13	0,51 a 0,77
LSTM (15 pruebas)	0,21 ± 0,21	0,91 ± 0,10	0,62 ± 0,17	0,42 a 0,83
Random Forest	0,50 ± 0,21	0,71 ± 0,16	0,62 ± 0,16	0,45 a 0,79
XGBoost	0,49 ± 0,21	0,71 ± 0,14	0,61 ± 0,16	0,44 a 0,77
Tramos largos, 3 variables elegidas	0,34 ± 0,17	0,84 ± 0,17	0,59 ± 0,17	0,41 a 0,77
Combinado (62 personas)				
Solo frecuencia dominante (EDA)	0,50 ± 0,18	0,82 ± 0,14	0,70 ± 0,13	0,56 a 0,84
Solo TUG	0,31 ± 0,17	0,90 ± 0,16	0,63 ± 0,17	0,45 a 0,80
Random Forest	0,52 ± 0,19	0,69 ± 0,15	0,62 ± 0,15	0,47 a 0,77
XGBoost	0,39 ± 0,17	0,69 ± 0,17	0,55 ± 0,14	0,40 a 0,70

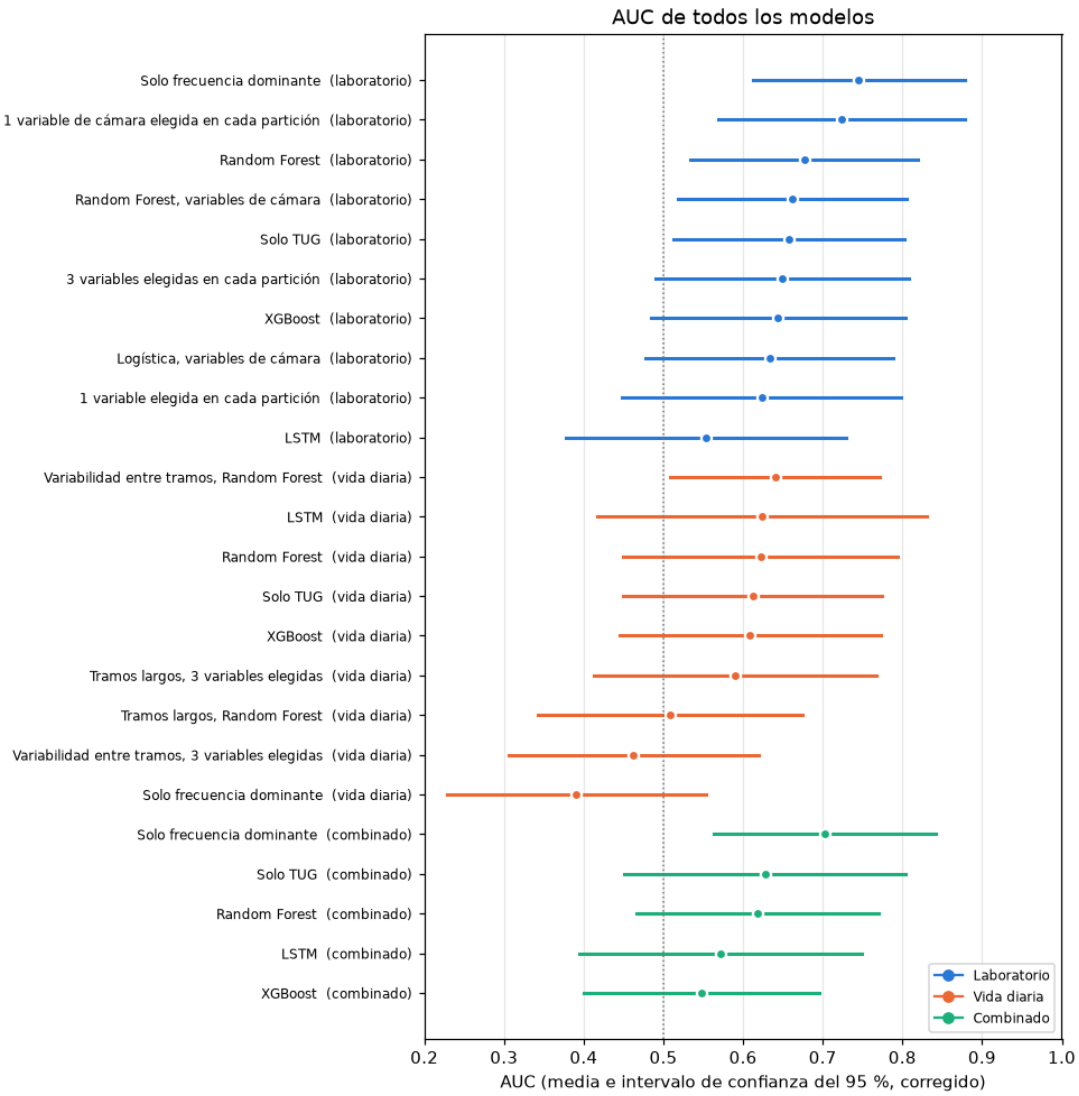


Fig. 1. AUC promedio e intervalo de confianza del 95 % (con varianza corregida) de todos los modelos, según la fuente de datos. La línea punteada marca el nivel del azar (0,5).

B. Comparación estadística

Ningún modelo fue significativamente peor que el mejor de su fuente de datos después de la corrección de Holm. Con laboratorio, el mejor fue la regresión logística con una variable de cámara elegida en cada partición (AUC 0,72), y sus diferencias con Random Forest (0,05), XGBoost (0,08) y la LSTM (0,20) no fueron significativas (p sin corregir de 0,51, 0,35 y 0,08). Los intervalos de confianza son anchos, de unos ±0,15, y se superponen casi por completo (Fig. 1). Con unas 70 personas, la validación no alcanza para distinguir modelos cuyo AUC difiere en menos de unos 0,15.

C. Sesgo de selección de la variable

Cuando se dejó que el modelo eligiera una variable entre las 14 dentro de cada partición, el AUC bajó de 0,75 a 0,62. La frecuencia dominante fue elegida solo en 28 de las 50 particiones; en las demás, el procedimiento eligió variables como el RMS de la aceleración anteroposterior, que en esa muestra de

entrenamiento parecían mejores (Fig. 2). En cambio, al elegir solo entre las variables medibles con cámara, la frecuencia dominante fue elegida en 46 de 50 particiones y el AUC fue de 0,72. Es decir, la ventaja de la frecuencia dominante es real, pero el 0,75 de la sub-etapa 1.3 estaba algo inflado, y la estimación honesta se encuentra entre 0,62 y 0,72 según cuántas variables compitan.

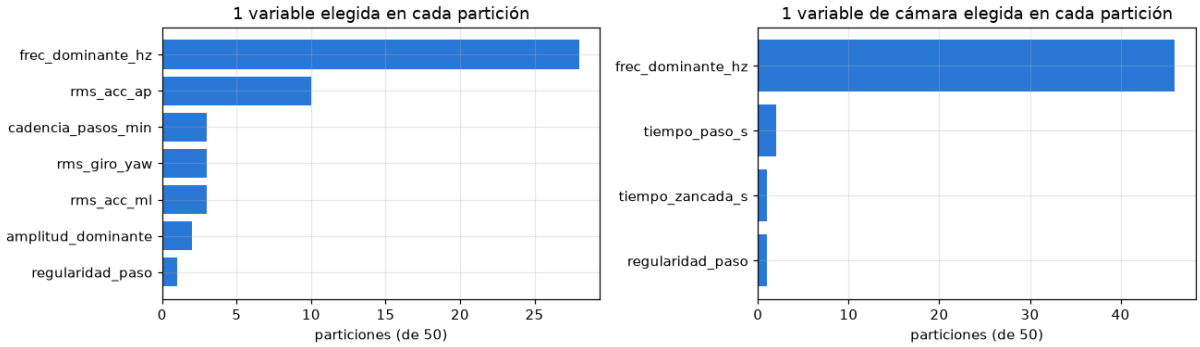


Fig. 2. Variable elegida en cada una de las 50 particiones por la regresión logística de una variable: entre todas las variables (izquierda) y solo entre las medibles con cámara (derecha).

D. Variantes de vida diaria

Ninguna variante de vida diaria mejoró la clasificación. La mejor, la variabilidad entre tramos con Random Forest, obtuvo un AUC de 0,64, apenas sobre el 0,62 del Random Forest original y sin diferencia significativa. Usar solo tramos largos no ayudó (0,51 a 0,59). Se mantiene, por lo tanto, el resultado negativo de la extensión con vida diaria.

E. Modelo seleccionado

La Tabla III resume la aplicación de los criterios. Los tres candidatos cumplieron el criterio de desempeño, y el más simple fue además el de mayor AUC. El modelo seleccionado es una regresión logística con la frecuencia dominante de la marcha, entrenada con las 72 personas. Su coeficiente estandarizado es de −0,87: cada desviación estándar de menor frecuencia aumenta el riesgo estimado, lo que concuerda con el análisis exploratorio, en el que quienes caen mostraron una frecuencia dominante menor (1,78 frente a 1,93 Hz).

TABLA III. Aplicación de los criterios de selección a los candidatos

Candidato (laboratorio, variables de cámara)	Variables	AUC	p Holm frente al mejor	Seleccionado
Regresión logística, 1 variable elegida en cada partición	**1**	**0,72**	**—**	**Sí**
Random Forest	9	0,66	1,00	No (más complejo)
Regresión logística	9	0,63	1,00	No (más complejo)

Con el umbral de 0,5, el modelo tiene una sensibilidad de 0,57 y una especificidad de 0,80. Para tamizaje se buscó el umbral que detecta al menos al 80 % de quienes caen: es de 0,40 (mediana de 10 repeticiones), y con él la especificidad baja a 0,47 ± 0,05 (Fig. 3). En otras palabras, para no dejar pasar a 8 de cada 10 personas que caen, el modelo daría una falsa alarma a aproximadamente la mitad de quienes no caen. El modelo, su umbral y los criterios de selección quedaron guardados para la Etapa 2.

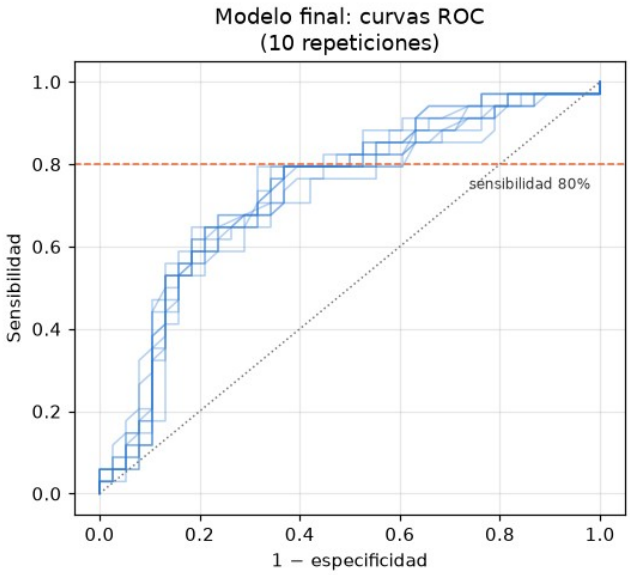


Fig. 3. Curvas ROC del modelo seleccionado en 10 repeticiones de la validación cruzada. La línea discontinua marca la sensibilidad objetivo de 80 %.

IV. Discusión

El resultado principal es que, con estos datos, no hay un modelo claramente superior. Las diferencias entre Random Forest, XGBoost, la LSTM, el TUG y los modelos de una variable están dentro de lo que se puede explicar por azar. Esto confirma la advertencia de Mou et al. [11] sobre los estudios con menos de 100 participantes, y justifica haber definido criterios de selección de antemano: cuando el desempeño no decide, deciden el uso real y la simplicidad. El plan del proyecto anticipa este escenario al señalar que un benchmark honesto es un resultado válido.

El modelo seleccionado es el más simple posible, y aun así no fue superado por ninguno de los modelos de aprendizaje automático. La frecuencia dominante mide el ritmo de la marcha a partir del espectro de la aceleración vertical; que funcione mejor que la cadencia, que mide lo mismo contando pasos, sugiere que la estimación espectral es más estable que la detección de pasos individuales en caminatas cortas. Esto es favorable para la Etapa 2: la frecuencia del movimiento vertical también puede estimarse con una cámara, por ejemplo siguiendo la altura de la cadera con MediaPipe, como ya se comprobó con el ritmo de las siluetas de CASIA en la sub-etapa 1.2.

El análisis del sesgo de selección es una contribución metodológica útil para el artículo. Elegir la variable mirando a todas las personas, como se hizo en el análisis exploratorio, infló el AUC en hasta 0,13 [9]. Este efecto es frecuente en la literatura de riesgo de caída y puede explicar parte de las diferencias con trabajos que reportan exactitudes mayores con la misma base, como el 82,2 % de Altunkaya [12].

Desde el punto de vista clínico, el modelo todavía es limitado: con una sensibilidad de 80 %, la especificidad es de 0,47. Sería útil como un primer filtro que indique a quién conviene hacerle una evaluación completa, no como diagnóstico. Además, como las etiquetas de LTMM son retrospectivas, el modelo reconoce a quienes ya cayeron y no predice caídas futuras.

V. Limitaciones y próximos pasos

Las principales limitaciones son el tamaño de la muestra, que deja intervalos de confianza de unos ±0,15 en el AUC; las etiquetas retrospectivas; y que la frecuencia dominante se midió con un acelerómetro en la espalda baja, mientras que en la Etapa 2 se medirá con una cámara. El conjunto de variables medibles con cámara se definió por criterio y debe confirmarse en la práctica. Los próximos pasos son:

- **Artículo (sub-etapa 1.5).** Redactar el artículo metodológico en plantilla IEEE, con el benchmark honesto, el análisis del sesgo de selección y el resultado negativo de la vida diaria como aportes principales.
- **Etapa 2.** Estimar la frecuencia dominante desde la pose de MediaPipe y compararla con la del sensor. El umbral de 0,40 deberá recalibrarse con las mediciones de cámara antes de usarse, y validarse en la prueba piloto de la sub-etapa 2.4.

VI. Productos

La Tabla IV lista los productos de esta sub-etapa, disponibles en el repositorio del proyecto.

TABLA IV. Productos de la sub-etapa 1.4

Archivo	Contenido
notebooks/ 05_Evaluacion_y_seleccion.ipynb	Comparación estadística, análisis definidos de antemano y selección del modelo final
resultados/tabla_comparativa.csv	Tabla comparativa de métricas de los 27 modelos y fuentes de datos
resultados/comparacion_estadistica.csv	Prueba t corregida y Holm de cada modelo frente al mejor de su fuente
resultados/metricas_por_particion_1_4.csv	Métricas por partición de los modelos nuevos
modelos/modelo_final.joblib, info_modelo_final.json	Modelo seleccionado, su umbral de tamizaje y la justificación
figuras/seleccion_*.png	Gráficos de esta sub-etapa

Referencias

[1] A. Weiss, M. Brozgol, M. Dorfman, T. Herman, S. Shema, N. Giladi, and J. M. Hausdorff, "Does the evaluation of gait quality during daily life provide insight into fall risk? A novel approach using 3-day

accelerometer recordings," Neurorehabil. Neural Repair, vol. 27, no. 8, pp. 742–752, 2013, doi: 10.1177/1545968313491004.

[2] J. M. Hausdorff, "Long Term Movement Monitoring Database," version 1.0.0, PhysioNet, 2016, doi: 10.13026/C2S59C.

[3] L. Breiman, "Random forests," Mach. Learn., vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[4] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Comput., vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[6] C. Nadeau and Y. Bengio, "Inference for the generalization error," Mach. Learn., vol. 52, no. 3, pp. 239–281, 2003, doi: 10.1023/A:1024068626366.

[7] R. R. Bouckaert and E. Frank, "Evaluating the replicability of significance tests for comparing learning algorithms," in Advances in Knowledge Discovery and Data Mining (PAKDD 2004), Lecture Notes in Computer Science, vol. 3056. Berlin, Germany: Springer, 2004, pp. 3–12.

[8] S. Holm, "A simple sequentially rejective multiple test procedure," Scand. J. Statist., vol. 6, no. 2, pp. 65–70, 1979.

[9] C. Ambroise and G. J. McLachlan, "Selection bias in gene extraction on the basis of microarray gene-expression data," Proc. Natl. Acad. Sci. USA, vol. 99, no. 10, pp. 6562–6566, 2002, doi: 10.1073/pnas.102102699.

[10] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," GigaScience, vol. 6, no. 5, Art. no. gix019, May 2017, doi: 10.1093/gigascience/gix019.

[11] C. Mou, X. Yan, X. Miao, and L. Zhu, "Accuracy of wearable devices in predicting falls in older adults: A systematic review and meta-analysis," Front. Public Health, vol. 14, Art. no. 1778750, Mar. 2026, doi: 10.3389/fpubh.2026.1778750.

[12] S. Altunkaya, "Leveraging feature selection for enhanced fall risk prediction in elderly using gait analysis," Med. Biol. Eng. Comput., vol. 62, pp. 3887–3897, 2024, doi: 10.1007/s11517-024-03180-2.